

Аннотация

Данная работа посвящена интеграции алгоритмов многоруких бандитов в задачи моделирования коллективной динамики мнений. В первой части сравниваются линейные контекстные алгоритмы (LinUCB, Lin-Thompson, Lin- ϵ -greedy) в синтетической задаче: LinUCB минимизирует ошибку предсказания наград, но уступает в точности восстановления весов. Во второй части построена мультиагентная модель, в которой агенты на графах Эрдёша–Реньи, Барабаши–Альберта и Ватса–Строгаца выбирают одну из пяти стратегий обновления мнения с помощью бандит-алгоритмов. Установлено, что наилучшую сходимость к внешней целевой позиции обеспечивает неконтекстный UCB, максимальную накопленную награду — контекстный Lin- ϵ -greedy, тогда как LinUCB и Lin-Thompson демонстрируют худшие результаты из-за мультиколлинеарности признаков в сетевой среде. В заключительной части исследуется робастный алгоритм FunctionalUCB, адаптивно оценивающий индекс хвоста распределения и ориентированный на максимизацию квантиля

Количество страниц – 66, количество иллюстраций – 20, количество таблиц – 12.

Оглавление

ВВЕДЕНИЕ	5
Глава 1 Модели динамики мнений и многорукие бандиты	11
1.1 Классические модели динамики мнений	11
1.2 Сравнительный обзор методов из литературы	13
1.3 Синтез динамики мнений и многоруких бандитов	15
Глава 2 Линейные многорукие бандиты	17
2.1 Постановка задачи	18
2.2 Модель агента	19
2.3 Связь с линейной регрессией	20
2.4 Сходимость и эффективность	23
2.5 Проведение экспериментов	25
Глава 3 Интеграция МАВ-алгоритмов в модели формирования мнений	30
3.1 Методы	32
3.2 Проведение экспериментов	35
Глава 4 Мультиагентная динамика мнений на разреженных графах	42
4.1 Логика функционирования агента	42
4.2 Реализация алгоритмов обучения	43
4.3 Топологии социальных сетей	44
4.4 Проведение симуляции	46
4.5 Сводные результаты экспериментов	46
4.6 Анализ результатов	49
Глава 5 Многорукий бандит с тяжёлыми хвостами и FunctionalUCB	53
5.1 Характеристика распределений с тяжёлыми хвостами	53
5.2 Алгоритм Functional UCB с адаптивной оценкой индекса Хилла	54
5.2.1 Постановка задачи	54
5.2.2 Оценка индекса хвоста и статистика Хилла	54
5.2.3 Обоснование выбора параметра $k(n)$	55
5.2.4 Решающее правило алгоритма	55

5.2.5	Сравнение с базовыми алгоритмами для тяжелых хвостов	56
5.2.6	Экспериментальная оценка на тяжёлых хвостах	57
	ЗАКЛЮЧЕНИЕ	61
	Список литературы	63

ВВЕДЕНИЕ

В последние годы задачи моделирования коллективного поведения и динамики мнений приобрели особую актуальность в связи с развитием социальных сетей, рекомендательных систем, цифровых платформ и многоагентных информационных сред. В таких системах пользователи не только обмениваются информацией, но и адаптируют собственное поведение на основе накопленного опыта, реакции окружающих и структуры доступных взаимодействий. Поэтому моделирование подобных процессов требует учета как социальной динамики, так и механизмов индивидуального обучения.

Классические модели динамики мнений, такие как модель ДеГрута и модель Фридкина–Джонсена, позволяют описывать достижение консенсуса, поляризацию и формирование устойчивых кластеров мнений в сети. Однако большинство таких моделей рассматривает агентов как пассивные элементы системы, которые обновляют мнение по заранее заданному правилу. В реальных цифровых средах агенты часто действуют иначе: они выбирают источники информации, каналы взаимодействия, собеседников и стратегии поведения, получая от среды стохастическую обратную связь.

Подобные процессы естественным образом описываются с помощью аппарата многоруких бандитов. Задача многорукого бандита формализует последовательное принятие решений в условиях неопределенности и отражает фундаментальный компромисс между исследованием новых действий и эксплуатацией уже известных эффективных стратегий. В контексте мультиагентных систем такие алгоритмы позволяют рассматривать агента как обучающийся субъект, который постепенно уточняет свои оценки действий и адаптирует поведение к среде.

В рамках теории многоруких бандитов существует несколько направлений, важных для моделирования интеллектуальных агентов. Первое направление связано с устойчивостью алгоритмов к шуму, выбросам и распределениям с тяжелыми хвостами. В таких условиях классические алгоритмы, основанные на среднем значении награды, могут демонстрировать нестабильное поведение. Для исследования этой проблемы в работе рассматривается алгоритм FunctionalUCB, использующий адаптивную оценку хвостового индекса распределения и ориентированный на квантильный критерий качества.

Второе направление связано с контекстным обучением. Во многих прикладных задачах награда зависит не только от выбранного действия, но и от признаков среды, характеристик агента, структуры сети и параметров взаимодействия. Для моделирования таких задач используются линейные многорукие бандиты, в которых ожидаемая награда представляется как функция от вектора признаков. Эти методы особенно важны для рекомендательных систем, социальных платформ и моделей адаптивного выбора взаимодействий.

Третье направление связано с коллективной динамикой мнений. Если отдельные агенты обладают механизмами обучения, то возникает вопрос о том, как индивидуальные стратегии выбора действий влияют на макроповедение системы: скорость достижения консенсуса, степень поляризации, устойчивость мнений и формирование кластеров. Именно поэтому в работе рассматривается мультиагентная модель, в которой агенты используют алгоритмы адаптивного обучения при взаимодействии в социальной сети.

Работа не предполагает прямого применения алгоритма FunctionalUCB к модели динамики мнений. Вместо этого исследование построено как анализ трех взаимосвязанных аспектов адаптивного обучения агентов: робастного обучения в условиях тяжелых хвостов, контекстного обучения и коллективной динамики обучающихся агентов. Общей методологической основой является последовательное принятие решений в стохастической среде.

Цель работы — исследовать различные механизмы адаптивного обучения агентов в стохастических и мультиагентных средах, а также проанализировать их влияние на поведение системы в условиях неопределенности.

Для достижения поставленной цели необходимо решить следующие задачи с критериями проверки:

1. Провести анализ классических моделей динамики мнений и алгоритмов многоруких бандитов. Критерий: в работе должны быть формально описаны модели ДеГроота и Фридкина–Джонсена, а также базовые алгоритмы многоруких бандитов: ϵ -greedy, UCB и Thompson Sampling. Для каждой группы методов должны быть указаны область применения, основные ограничения и связь с задачей адаптивного выбора стратегий агентами.

2. Реализовать линейные многорукие бандиты для задачи последовательного выбора действий с контекстными признаками. Критерий: должны быть реализованы и сравнены LinUCB, Thompson Sampling и ϵ -greedy в синтетической линейной среде с числом действий $K = 10$, размерностью признаков $d = 7$, шумом наблюдений $\varepsilon_t \sim N(0, 0.1^2)$ и истинным вектором весов $w^* \sim N(0, I_d)$.
3. Оценить качество контекстного обучения по ошибке восстановления параметров и ошибке предсказания наград. Критерий: для каждого алгоритма должны быть построены траектории ошибки оценки весов

$$e_t^{weight} = \|\hat{w}_t - w^*\|_2$$

и средней ошибки предсказания наград

$$e_t^{pred} = \frac{1}{K} \sum_{a=1}^K |\hat{r}_{t,a} - w^{*\top} x_a|.$$

При анализе результатов необходимо отдельно указать, что основная цель бандит-алгоритма состоит не в точном восстановлении w^* , а в выборе действий с высокой ожидаемой наградой.

4. Интегрировать МАВ-алгоритмы в модели формирования мнений. Критерий: в модели должно быть явно определено, что является ручкой бандита. В эксперименте с выбором собеседника ручка соответствует доступному партнёру по взаимодействию, а в мультиагентной модели на графах ручка соответствует стратегии обновления мнения. Для каждого случая должна быть задана функция награды, по которой агент обновляет оценки действий.
5. Построить мультиагентную модель динамики мнений с пятью стратегиями-руками. Критерий: каждый агент должен иметь мнение $x_i(t) \in [0, 1]$, множество соседей, задаваемое графом, и набор стратегий обновления мнения:

$$A_i = \{\text{Stubborn, Average, Compromise, Drift Up, Drift Down}\}.$$

На каждом шаге агент выбирает одну из стратегий с помощью заданного бандит-алгоритма, обновляет мнение и получает награду, связанную с приближением к внешней целевой позиции θ .

6. Провести эксперименты на разреженных графах разных топологий. Критерий: модель должна быть протестирована на графах Эрдёша–Реньи (ER), Барабаши–Альберт (BA) и Уотса–Строгаца (WS). Для каждой топологии сравниваются неконтекстные алгоритмы ε -greedy, UCB и Thompson Sampling, а также контекстные алгоритмы LinUCB, Lin-Thompson и Lin- ε -greedy.
7. Сравнить алгоритмы по метрикам коллективной динамики мнений. Критерий: для каждой пары “алгоритм–топология” должны быть рассчитаны:

$$\bar{x}_T = \frac{1}{N} \sum_{i=1}^N x_i(T),$$

$$e_T = |\bar{x}_T - \theta|,$$

а также накопленная награда:

$$R = \sum_{t=1}^T \sum_{i=1}^N r_i(t).$$

Дополнительно должна быть указана стандартная ошибка среднего по независимым запускам.

8. Проанализировать, сохраняется ли преимущество контекстных бандитов в сетевой мультиагентной среде. Критерий: результаты должны быть интерпретированы отдельно для неконтекстных и контекстных алгоритмов. Если контекстные алгоритмы уступают неконтекстным, необходимо указать, что этот вывод относится к данной конфигурации контекстного вектора и не означает общего проигрыша контекстных бандитов во всех задачах динамики мнений.
9. Реализовать и экспериментально оценить алгоритм FunctionalUCB с адаптивной оценкой хвостового индекса. Критерий: алгоритм должен быть протестирован на синтетических распределениях Парето, Коши и нормальном распределении при горизонте моделирования $T = 3000$. Качество алгоритма оценивается по кумулятивному квантильному регрету:

$$R_T^{quantile} = \sum_{t=1}^T (Q_{i^*}(q) - Q_{i_t}(q)),$$

где $q = 0.75$, $Q_i(q)$ — истинный q -квантиль распределения наград ручки i , а i^* — ручка с максимальным значением данного квантиля.

10. Сравнить FunctionalUCB с базовыми подходами в условиях тяжёлых и лёгких хвостов. Критерий: для каждого распределения должны быть построены графики среднего кумулятивного квантильного регрета по независимым запускам. Отдельно фиксируется, в каких условиях FunctionalUCB превосходит классический UCB, а в каких уступает ему из-за избыточного исследовательского бонуса. Результаты интерпретируются именно в терминах квантильного регрета, а не классического регрета по математическому ожиданию.
11. Сформулировать выводы о влиянии бандит-алгоритмов на динамику мнений. Критерий: по результатам экспериментов необходимо определить, какие алгоритмы обеспечивают меньшую ошибку относительно целевой позиции θ , какие дают большую накопленную награду, и как топология графа влияет на устойчивость полученных результатов.

Объект исследования — Мнения агентов.

Предмет исследования — Алгоритмы многоруких бандитов и их использование для моделирования робастного, контекстного и коллективного поведения агентов.

Научная новизна работы заключается в комплексном рассмотрении нескольких аспектов адаптивного обучения агентов: робастного обучения в условиях тяжелых хвостов, контекстного обучения и мультиагентной динамики мнений. В работе предложена единая исследовательская логика, в которой различные классы bandit-алгоритмов рассматриваются как механизмы индивидуального и коллективного поведения агентов.

Практическая значимость работы состоит в возможности применения рассмотренных моделей для анализа поведения пользователей в социальных сетях, рекомендательных системах, системах распространения информации и других цифровых средах, где агенты принимают решения в условиях неопределенности.

Исследовательская логика работы

В данной работе рассматриваются три взаимосвязанных направления адаптивного обучения агентов.

Первое направление связано с контекстным обучением. Оно рассматривается в главе 2 на примере линейных многоруких бандитов. В отличие от классического МAB, здесь агент учитывает признаки действия и среды.

Второе направление связано с коллективной динамикой мнений. Оно рассматривается в главах 3 и 5, где агенты помещаются в социальную сеть и используют алгоритмы обучения для выбора взаимодействий.

Первое направление связано с робастным обучением в стохастической среде. Оно рассматривается в главе 5 на примере алгоритма FunctionalUCB, предназначенного для распределений с тяжелыми хвостами. .

Глава 1 Модели динамики мнений и многорукие бандиты

1.1. Классические модели динамики мнений

История математического моделирования динамики мнений начинается с середины XX века, когда в рамках теории социальных сетей и теории группового влияния начали появляться формализованные модели коллективных убеждений. Одной из ключевых точек отсчёта стала модель де Гроота [19], в которой каждый агент i в сети обновляет своё мнение как взвешенное среднее мнений соседей:

$$x_i(t+1) = \sum_{j=1}^n w_{ij} x_j(t), \quad (1.1)$$

где $x_i(t) \in \mathbb{R}$ — значение мнения агента i , а веса $w_{ij} \geq 0$ удовлетворяют условиям $\sum_j w_{ij} = 1$ и $w_{ij} = 0$ при отсутствии связи между агентами i и j [19, 26]. Матрица $W = (w_{ij})$ интерпретируется как матрица влияния, а условие достижения консенсуса в пределе $t \rightarrow \infty$ связано с наличием общего ведущего аттрактора в спектре матрицы W .

В дальнейшем модель де Гроота была обобщена в рамках модели Фридкина–Джонсена, в которой учитывается «привязанность» агента к своему изначальному убеждению [26]. В дискретной форме модель записывается так:

$$x_i(t+1) = \alpha_i s_i + (1 - \alpha_i) \sum_{j \in \mathcal{N}_i} w_{ij} x_j(t), \quad (1.2)$$

где s_i — начальное мнение агента, $\alpha_i \in [0, 1]$ — параметр, отражающий степень его замкнутости относительно внешнего влияния, а $\mathcal{N}_i$ — множество соседей агента. Введение такого внутреннего мнения s_i позволило более реалистично описывать процессы поляризации и застойных конфликтов мнений, а также анализировать условия, при которых достигается консенсус или формируются устойчивые кластеры разногласий [2, 26].

В последующие десятилетия модели динамики мнений активно развивались в рамках теории управления и теории сетей. В работах советских и российских авторов рассматривались задачи управляемости коллективных мнений, условия устойчивости

и влияние структуры сети на достижение консенсуса [2, 50]. В XXI веке интерес к динамике мнений резко возрос в контексте социальных сетей и цифровых платформ, где особую важность приобрели вопросы информационной безопасности, манипулирования мнениями и формирования так называемых «эхо-камер» [3, 33].

Параллельно с развитием моделей динамики мнений происходило становление и активное развитие теории многоруких бандитов, которая стала одной из ключевых дисциплин в области онлайн-оптимизации и обучения с подкреплением. Истоки этой задачи восходят к классическим работам по последовательному анализу, где в 1930-е годы Г. Роббинс и его последователи рассматривали вопросы оптимального выбора между несколькими альтернативами при неполной информации [37]. В 1952 году Роббинс впервые формализовал задачу многорукого бандита как проблему баланса между исследованием и эксплуатацией: на каждом шаге t агент выбирает действие $a_t \in \{1, \dots, K\}$, получает случайную награду $r_t \sim \nu_{a_t}$ и стремится максимизировать совокупную ожидаемую награду:

$$\max \mathbb{E} \left[\sum_{t=1}^T r_t \right], \quad (1.3)$$

где T — горизонт времени, а ν_k — неизвестное распределение награды для действия k [10, 39]. В рамках этой постановки внимание было сосредоточено на построении политик, которые минимизируют регрет — разницу между ожидаемой наградой оптимальной стратегии и реализовавшейся стратегии агента.

В 1980-е и 1990-е годы задача многорукого бандита была глубоко изучена в теории оптимизации и теории вероятностей, появилась серия «классических» стратегий, в том числе семейство UCB-алгоритмов, основанных на верхней доверительной границе для оценки средней награды каждого действия [10, 30]. В рамках UCB-подхода агент поддерживает оценку средней награды $\hat{r}_k(t)$ для каждого действия k и число его выборов $n_k(t)$, а затем выбирает действие, максимизирующее индекс:

$$\text{UCB}_k(t) = \hat{r}_k(t) + \sqrt{\frac{2 \log t}{n_k(t)}}. \quad (1.4)$$

В дискретной форме правило выбора имеет вид:

$$a_t \in \arg \max_{k \in \{1, \dots, K\}} \text{UCB}_k(t). \quad (1.5)$$

Этот асимптотически оптимальный алгоритм обеспечивает естественный компромисс между исследованием малопосещаемых действий и эксплуатацией уже хорошо оценённых стратегий, а его поведение хорошо изучено как в стационарных, так и в нестационарных средах [10, 39].

В качестве простой и практически популярной эвристики широко используется стратегия ε -greedy, при которой с фиксированной вероятностью $\varepsilon \in (0, 1)$ агент выбирает случайное действие для исследования, а с вероятностью $1 - \varepsilon$ — действие с наибольшей текущей оценкой награды:

$$\mathbb{P}(a_t = k) = \begin{cases} \varepsilon/K, & \text{если выбор исследования,} \\ 1 - \varepsilon, & \text{если } k \in \arg \max_l \hat{r}_l(t). \end{cases} \quad (1.6)$$

Этот алгоритм легко реализуется и часто используется в рекомендательных системах и онлайн-экспериментах, однако его асимптотическая эффективность остаётся хуже, чем у UCB-методов, особенно в средах с большим числом действий [?, 39].

Ещё одним мощным подходом является метод Томпсона (Thompson sampling), в котором агент поддерживает апостериорное распределение параметров наград для каждого действия и производит выбор стратегии через сэмплирование из этих распределений [45]. В случае биномиальных или нормальных моделей это можно записать в виде:

$$\theta_k^{(t)} \sim \text{Posterior}_k(t), \quad a_t \in \arg \max_{k \in \{1, \dots, K\}} \theta_k^{(t)}, \quad (1.7)$$

где $\theta_k^{(t)}$ — параметр, отражающий «предполагаемую» среднюю награду для действия k согласно текущему апостериору [39]. По ряду результатов, Thompson sampling демонстрирует асимптотически оптимальное поведение и часто превосходит как UCB, так и ε -greedy в практических экспериментах, особенно при наличии структуры распределения наград [6, 41].

1.2. Сравнительный обзор методов из литературы

В области динамики мнений можно выделить несколько ключевых направлений, различающихся по способу описания обновления убеждений и структуре сети. Классические модели де Гроота и Фридкина–Джонсена предполагают фиксированный набор

соседей и линейное правило обновления, что позволяет получать строгие аналитические результаты, но ограничивает гибкость моделей в условиях меняющейся структуры связи [2, 19, 26]. В более современных постановках рассматриваются нелинейные и стохастические модели, а также модели, в которых веса влияния w_{ij} могут динамически меняться во времени, что повышает реалистичность, но усложняет математический анализ [3, 33].

В параллельных направлениях появляется целый ряд работ, в которых агенты не только обновляют свои мнения, но и выбирают правила обновления или каналы информации с помощью механизмов, близких к многоруким бандитам. В ряде работ рассматривается постановка, где агент выбирает, из какого набора источников информации получать сигналы, полагаясь на баланс между исследованием новых источников и эксплуатацией уже проверенных, а использование бандит-алгоритмов позволяет одновременно учесть и рейтинг источника, и структуру его влияния на сеть [33, 48]. В некоторых моделях многорукие бандиты применяются для совместного обучения структуры сети и правил динамики мнений, то есть матрица влияния W и функции обновления выбираются одновременно, что позволяет автоматически выявлять наиболее значимые связи и типы взаимодействия [2, 48].

Если перейти к сравнению конкретных бандит-алгоритмов, можно выделить несколько ключевых характеристик, которые обычно анализируются в литературе [?, 10, 39]:

- асимптотическая оптимальность регрета;
- чувствительность к выбору гиперпараметров (например, параметра ε или коэффициента в корне UCB);
- удобство применения в средах с большим числом действий или с изменяющейся наградной структурой.

В этом контексте ε -greedy обычно выступает в роли бенчмарка: простой в реализации и интерпретируемый, но асимптотически менее эффективный, чем UCB и Thompson sampling. UCB-алгоритмы обеспечивают хороший баланс между теоретической оптимальностью и практической применимостью, особенно в задачах, где можно достоверно оценивать дисперсию наград. Thompson sampling показывает высокую производительность в задачах с хорошо заданными априорными распределениями, и в ряде экспе-

риментов демонстрирует меньший регрет по сравнению с UCB, особенно при наличии структуры в распределении вероятностей наград [6, 41].

1.3. Синтез динамики мнений и многоруких бандитов

В рассматриваемой работе предлагается синтезировать эти две ветви исследований: с одной стороны — богатую историю моделей динамики мнений, восходящую к де Грооту и Фридкину–Джонсену, а с другой — современный аппарат многоруких бандитов для описания того, как отдельные агенты выбирают свои стратегии взаимодействия с окружающей средой и соседями в социальной сети. В мультиагентной системе каждый агент i имеет множество доступных стратегий $A_i = \{1, \dots, K\}$, выбирает стратегию $a_i(t)$ на каждом шаге, получает награду $r_i(t)$ (например, связанную с социальным вовлечением, доверием или информационной полезностью) и обновляет оценку средней награды каждой стратегии, например, по правилу:

$$\hat{r}_{i,k}(t+1) = \frac{n_{i,k}(t) \hat{r}_{i,k}(t) + r_{i,k}(t)}{n_{i,k}(t) + 1}, \quad (1.8)$$

где $n_{i,k}(t)$ — число выборов стратегии k агентом i к моменту t [?, 39]. На основе полученных оценок агент формирует своё внутреннее мнение $x_i^{\text{int}}(t)$, которое может быть функцией от набора $\hat{r}_{i,k}(t)$, а затем обновляет своё публичное мнение согласно модифицированной версии модели Фридкина–Джонсена:

$$x_i(t+1) = \alpha_i x_i^{\text{int}}(t) + (1 - \alpha_i) \sum_{j \in \mathcal{N}_i} w_{ij} x_j(t). \quad (1.9)$$

Здесь $x_i^{\text{int}}(t)$ может строиться, например, через выбор наиболее успешной стратегии (greedy-правило), через UCB-индекс или через выбор стратегии по методу Томпсона, в зависимости от выбранного бандит-алгоритма [10, 39].

Такой подход позволяет моделировать, как обучаемость агентов на уровне стратегий (через механизмы ε -greedy, UCB или Thompson sampling) влияет на макроскопические свойства коллективного мнения: скорость достижения квази-консенсуса, устойчивость к шуму и помехам, склонность к поляризации и формированию структурных кластеров мнений [2, 33, 50]. В ряде недавних работ агенты выбирают правила обновления мнений или каналы информации с помощью бандит-механизмов, а в отдельных моделях многорукие бандиты используются для совместного обучения структуры сети

и правил динамики, что позволяет автоматически выявлять значимые связи и типы взаимодействия [33, 48].

Таким образом, предметом настоящей работы является моделирование динамики мнений, в которой каждый агент выбирает стратегию взаимодействия с помощью многоруких бандитов.

Глава 2 Линейные многорукие бандиты

Базовые алгоритмы многоруких бандитов, такие как ϵ -greedy, UCB и Thompson sampling, позволяют эффективно описывать выбор стратегий в условиях ограниченной информации, однако в ряде приложений, связанных с социальными сетями и рекомендательными системами, недостатком простых бандитов является их игнорирование структуры наблюдаемых признаков. В реальных цифровых средах действия агентов (например, выбор контента, типа взаимодействия или канала информации) часто сопровождаются большим количеством контекстуальной информации: о самом агенте (его профиль, интересы, поведение), о его соседях и о текущем состоянии сети. В таких условиях становится естественным перейти от «табличной» модели бандита с фиксированным набором действий к более гибкой *контекстуальной* постановке, в которой награда зависит от векторов признаков, связанных с каждым действием.

В рамках этого подхода возникает класс задач, известных как *линейные многорукие бандиты* (linear bandits). В отличие от классических бандитов, где каждое действие $k \in \{1, \dots, K\}$ характеризуется лишь скалярной неизвестной средней наградой μ_k , в линейной модели предполагается, что средняя награда действия a зависит от связанного с ним вектора признаков $\mathbf{x}_a \in \mathbb{R}^d$ и неизвестного вектора параметров $\boldsymbol{\theta}^* \in \mathbb{R}^d$:

$$\mathbb{E}[r_a] = \boldsymbol{\theta}^{*\top} \mathbf{x}_a. \quad (2.1)$$

Таким образом, награды разных действий оказываются связанными единой линейной моделью, что позволяет переносить информацию между действиями и сокращать количество необходимых пробных шагов, особенно при большом числе вариантов. В социальных приложениях это означает, что агенты могут учиться не только по отдельным стратегиям, но и по общей структуре их «представления» (например, по тематике контента, типу взаимодействия или социальным признакам).

Исторически развитие линейных бандитов шло параллельно с развитием онлайн-регрессии и методов оптимизации. В 2000-е годы появились первые теоретические работы, посвящённые регрет-анализу для линейных моделей, а в дальнейшем были предложены такие алгоритмы, как LinUCB и LinTS, которые обобщают идеи верхней

доверительной границы (UCB) и Thompson sampling на случай линейной зависимости награды от признаков [40]. В LinUCB-подходе агент поддерживает линейную модель $\hat{\theta}_t$ и соответствующую неопределённость (ковариационную матрицу V_t), а затем выбирает действие, максимизирующее индекс:

$$a_t \in \arg \max_a \left(\hat{\theta}_t^\top \mathbf{x}_a + \beta_t \sqrt{\mathbf{x}_a^\top V_t^{-1} \mathbf{x}_a} \right), \quad (2.2)$$

где коэффициент β_t управляет балансом между исследованием и эксплуатацией [?]. В LinTS вместо детерминированного индекса используется сэмплирование из апостериорного распределения параметров:

$$\tilde{\theta}_t \sim \text{Posterior}_t, \quad a_t \in \arg \max_a \tilde{\theta}_t^\top \mathbf{x}_a, \quad (2.3)$$

что позволяет естественным образом учитывать неопределённость в модели и адаптивно перераспределять усилия между действиями [40].

В контексте рассматриваемой работы линейные бандиты представляют собой естественное обобщение базовых бандит-алгоритмов, которое позволяет:

- вводить в модель контекст агента и его окружения (например, социальные признаки, история поведения, тематика контента);
- учитывать взаимную зависимость между стратегиями (через общую линейную модель награды);
- эффективно обобщать опыт между действиями, что особенно важно в социальных сетях с большим числом возможных вариантов взаимодействия.

Цель данной главы состоит в том, чтобы ввести формальный аппарат линейных многоруких бандитов и описать основные алгоритмы (LinUCB, LinTS, LinEpsilon).

2.1. Постановка задачи

Рассмотрим задачу последовательного принятия решений в дискретном времени $t = 1, 2, \dots, T$. На каждом шаге агенту предлагается выбрать действие a_t из множества доступных действий (рук) $\mathcal{A}_t = \{1, \dots, K\}$, где K — количество доступных собеседников.

Каждое действие $a \in \mathcal{A}_t$ характеризуется вектором признаков $\mathbf{x}_{t,a} \in \mathbb{R}^d$, где d — размерность пространства признаков [18]. Вектор $\mathbf{x}_{t,a}$ включает в себя характеристики собеседника и контекст взаимодействия.

Предполагается, что математическое ожидание награды линейно зависит от признаков выбранного действия:

$$\mathbb{E}[r_t \mid a_t = a, \mathbf{x}_{t,a}] = \mathbf{w}^* \cdot \mathbf{x}_{t,a}, \quad (2.4)$$

где $\mathbf{w}^* \in \mathbb{R}^d$ — неизвестный вектор истинных весов среды.

Фактическая наблюдаемая награда r_t включает аддитивный гауссовский шум:

$$r_t = \mathbf{w}^* \cdot \mathbf{x}_{t,a_t} + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2), \quad (2.5)$$

где σ^2 — дисперсия шума наблюдений [31].

Целью агента является максимизация совокупной награды за горизонт T , что эквивалентно минимизации кумулятивного регрета:

$$R(T) = \sum_{t=1}^T (\mathbf{w}^* \cdot \mathbf{x}_{t,a_t^*} - \mathbf{w}^* \cdot \mathbf{x}_{t,a_t}), \quad (2.6)$$

где $a_t^* = \arg \max_{a \in \mathcal{A}_t} \mathbf{w}^* \cdot \mathbf{x}_{t,a}$ — оптимальное действие на шаге t .

Хороший алгоритм должен обеспечивать сублинейный рост регрета, то есть $R(T)/T \rightarrow 0$ при $T \rightarrow \infty$. Это означает, что средняя награда агента сходится к оптимальной [14].

2.2. Модель агента

Агент не знает истинный вектор $\mathbf{w}^*$, но рассчитывает его оценку $\hat{\mathbf{w}}_t$, которая обновляется по мере получения новых данных [32]. Предсказанная награда для действия a вычисляется как:

$$\hat{r}_{t,a} = \hat{\mathbf{w}}_t \cdot \mathbf{x}_a. \quad (2.7)$$

После выбора действия a_t и получения награды r_t агент обновляет оценку весов. Ошибка предсказания вычисляется как разница между фактической и предсказанной наградой [43]:

$$\delta_t = r_t - \hat{\mathbf{w}}_t \cdot \mathbf{x}_{a_t}. \quad (2.8)$$

Обновление весов происходит по правилу:

$$\hat{\mathbf{w}}_{t+1} = \hat{\mathbf{w}}_t + \alpha \cdot \delta_t \cdot \mathbf{x}_{a_t}, \quad (2.9)$$

где $\alpha > 0$ — скорость обучения (параметр, определяющий размер шага обновления).

Интерпретация:

- Если предсказание было слишком низким ($\delta_t > 0$), веса увеличиваются в направлении признаков выбранного действия;
- Если предсказание было слишком высоким ($\delta_t < 0$), веса уменьшаются;
- Чем больше ошибка, тем сильнее корректировка.

Для повышения устойчивости модели можно использовать маску $\mathbf{m} \in \{0, 1\}^d$, которая отключает невыраженные у собеседника признаки [32]:

$$\hat{\mathbf{w}}_{t+1} = \hat{\mathbf{w}}_t + \alpha \cdot \delta_t \cdot (\mathbf{m} \odot \mathbf{x}_{a_t}), \quad (2.10)$$

где $\odot$ обозначает поэлементное умножение.

Компоненты маски определяются пороговым значением τ :

$$m_i = \begin{cases} 1, & \text{если } |x_{a_t}^{(i)}| > \tau, \\ 0, & \text{иначе.} \end{cases} \quad (2.11)$$

Это позволяет игнорировать признаки с малыми значениями, которые могут вносить шум в обновления.

2.3. Связь с линейной регрессией

Математическая основа линейного бандита тесно связана с классической задачей линейной регрессии, в которой целевая переменная (награда) моделируется как линейная комбинация признаков наблюдаемого вектора. В данном подразделе рассматривается формальная связь между постановкой линейного бандита и задачей последовательной линейной регрессии, а также обсуждается, как стандартные методы оценивания параметров регрессионной модели (например, метод наименьших квадратов или байесовская регрессия) интерпретируются в контексте бандит-алгоритмов.

В классической линейной регрессии предполагается, что наблюдаемые отклики y_t связаны с векторами признаков $\mathbf{x}_t$ линейным соотношением:

$$y_t = \boldsymbol{\theta}^{*\top} \mathbf{x}_t + \varepsilon_t, \quad (2.12)$$

где $\boldsymbol{\theta}^* \in \mathbb{R}^d$ — неизвестный вектор параметров, а ε_t — шум с нулевым математическим ожиданием. В задаче линейного бандита можно рассматривать каждое действие a_t как выбор вектора признаков $\mathbf{x}_{a_t}$, а наблюдаемую награду r_t — как отклик в линейной модели с фиксированным, но неизвестным вектором $\boldsymbol{\theta}^*$. В этом смысле линейный бандит

представляет собой *онлайн-версию* линейной регрессии, в которой агент последовательно выбирает точки в пространстве признаков, получает отклики и строит итеративные оценки параметров модели, одновременно стремясь максимизировать суммарную награду.

Такая связь позволяет напрямую переносить идеи из линейной регрессии в построение бандит-алгоритмов. Например, оценка методом наименьших квадратов на множестве наблюждённых пар $(\mathbf{x}_t, r_t)$ естественно интерпретируется как текущая оценка вектора параметров $\boldsymbol{\theta}^*$, а ковариационная матрица оценки определяет меру неопределённости в каждом направлении признакового пространства. В таком контексте некоторые популярные линейные бандит-алгоритмы можно рассматривать как регрессионные процедуры, расширенные правилами выбора действий, которые учитывают как текущую оценку $\boldsymbol{\theta}_t$, так и её неопределённость.

Рассмотрим функцию потерь как средний квадрат ошибки предсказания для текущего вектора весов $\mathbf{w}$:

$$L(\mathbf{w}) = \frac{1}{2} (r_t - \mathbf{w}^\top \mathbf{x}_{a_t})^2. \quad (2.13)$$

Минимизация такой функции потерь в классической регрессии позволяет подобрать вектор весов $\mathbf{w}$, который наилучшим образом соответствует наблюдаемым данным, а в контексте бандита — оценить неизвестный параметр $\boldsymbol{\theta}^*$, определяющий зависимость награды от признаков.

Градиент этой функции по вектору весов равен:

$$\nabla_{\mathbf{w}} L(\mathbf{w}) = - (r_t - \mathbf{w}^\top \mathbf{x}_{a_t}) \mathbf{x}_{a_t}. \quad (2.14)$$

На основе градиента можно выполнить один шаг градиентного спуска, чтобы обновить текущую оценку весов:

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \alpha \nabla_{\mathbf{w}} L(\mathbf{w}_t) = \mathbf{w}_t + \alpha (r_t - \mathbf{w}_t^\top \mathbf{x}_{a_t}) \mathbf{x}_{a_t}, \quad (2.15)$$

где $\alpha > 0$ — шаг обучения, контролирующий скорость обновления оценки.

Это в точности совпадает с правилом обновления весов, которое естественным образом возникает, когда агент онлайн-обучает линейную модель на основе каждого нового наблюдения $(\mathbf{x}_{a_t}, r_t)$ [32]. Таким образом, агент фактически выполняет последовательное обучение линейной регрессии, но в динамическом режиме, где на каждом

шаге он как производит прогноз награды (для выбора действия), так и немедленно обновляет свою модель по вновь полученной информации. В такой интерпретации многорукий бандит выступает в роли контроллера, который выбирает точку в пространстве признаков, а реализовавшееся значение награды используется как целевой отклик этой точки в регрессионной модели.

Для улучшения устойчивости и качества оценок в линейных моделях широкое распространение получает L_2 -регуляризация, которая добавляет штраф за большие значения весов и тем самым регулирует сложность модели [18]. В онлайн-режиме такая регуляризация часто применяется к совокупности всех прошлых наблюдений. В этом случае функция потерь принимает вид:

$$L_{\text{ridge}}(\mathbf{w}) = \frac{1}{2} \sum_{i=1}^t (r_i - \mathbf{w}^\top \mathbf{x}_i)^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2, \quad (2.16)$$

где $\lambda > 0$ — параметр регуляризации, контролирующий степень штрафа за величину нормы вектора весов. Введение регуляризатора $\frac{\lambda}{2} \|\mathbf{w}\|_2^2$ позволяет избегать переобучения на малом числе наблюдений, стабилизировать оценки и улучшать их обобщающую способность, особенно в ситуациях, когда агент активно исследует разнообразные стратегии и признаки вектора.

Решение задачи ридж-регрессии имеет замкнутую аналитическую форму:

$$\hat{\mathbf{w}}_t = (\mathbf{X}_t^\top \mathbf{X}_t + \lambda \mathbf{I})^{-1} \mathbf{X}_t^\top \mathbf{r}_t, \quad (2.17)$$

где $\mathbf{X}_t$ — матрица, строки которой соответствуют векторам признаков $\mathbf{x}_i$ всех наблюдаемых действий до момента t , а $\mathbf{r}_t$ — вектор полученных наград r_i [4]. Этот подход обеспечивает глобальную оптимизацию по совокупности наблюдений и даёт более устойчивые оценки, чем простой градиентный спуск. Однако в онлайн-режиме вычисление обратной матрицы $(\mathbf{X}_t^\top \mathbf{X}_t + \lambda \mathbf{I})^{-1}$ на каждом шаге становится вычислительно затратным, особенно при росте t .

Поэтому в линейных бандитах, в частности в алгоритме LinUCB, используется экономичное представление этой задачи через рекуррентное обновление двух мат-

риц [4]:

$$\mathbf{A}_t = \mathbf{A}_{t-1} + \mathbf{x}_t \mathbf{x}_t^\top, \quad \mathbf{A}_0 = \lambda \mathbf{I}, \quad (2.18)$$

$$\mathbf{b}_t = \mathbf{b}_{t-1} + r_t \mathbf{x}_t, \quad \mathbf{b}_0 = \mathbf{0}, \quad (2.19)$$

$$\hat{\mathbf{w}}_t = \mathbf{A}_t^{-1} \mathbf{b}_t. \quad (2.20)$$

Здесь матрица $\mathbf{A}_t$ совпадает с $\mathbf{X}_t^\top \mathbf{X}_t + \lambda \mathbf{I}$, а вектор $\mathbf{b}_t$ — с $\mathbf{X}_t^\top \mathbf{r}_t$, поэтому рекуррентные обновления обеспечивают те же результаты, что и полная переоценка модели на каждом шаге, но при значительно меньшей вычислительной сложности. В результате агент получает стабильную и регуляризованную оценку $\hat{\mathbf{w}}_t$, которая используется для предсказания средней награды каждого действия и, в дальнейшем, для формирования индексов выбора стратегий.

2.4. Сходимость и эффективность

При выполнении определённых условий последовательные оценки вектора весов линейной модели сходятся к истинным значениям:

$$\hat{\mathbf{w}}_t \rightarrow \boldsymbol{\theta}^* \quad \text{при} \quad t \rightarrow \infty. \quad (2.21)$$

Этот факт можно интерпретировать как утверждение о том, что агент, выбирая стратегии и наблюдая награды, постепенно «высвечивает» истинную структуру зависимости награды от признаков. В рамках теории стохастического градиентного спуска и линейной регрессии такие результаты обосновываются в предположении, что агент систематически исследует пространство признаков и не «забывает» никогда полностью предыдущие данные [31, 43].

Для того чтобы такая сходимость имела место, необходимо выполнение двух ключевых условий:

- каждое действие (или, более точно, каждое направление в признаковом пространстве, которое соответствует какому-либо действию) должно выбираться агентом бесконечное число раз, чтобы обеспечить достаточную «покрытость» наблюдений в пространстве $\mathbb{R}^d$;

- скорость обучения α_t должна удовлетворять классическим условиям сходимости стохастического градиентного спуска:

$$\sum_{t=1}^{\infty} \alpha_t = \infty, \quad \sum_{t=1}^{\infty} \alpha_t^2 < \infty, \quad (2.22)$$

что обеспечивает достаточно агрессивное обучение в начале и постепенное затухание вклада новых шагов к концу.

При таких предположениях оценка $\hat{\mathbf{w}}_t$ постепенно сосредотачивается вокруг истинного параметра $\boldsymbol{\theta}^*$, а средняя квадратичная ошибка оценок убывает со скоростью, обратной числу наблюдений:

$$\mathbb{E} [\|\hat{\mathbf{w}}_t - \boldsymbol{\theta}^*\|_2^2] = O\left(\frac{1}{t}\right). \quad (2.23)$$

Это означает, что точность оценок постепенно увеличивается по мере накопления данных, а при больших t отклонение оценки от истинного вектора параметров становится малым.

Такая асимптотическая сходимость играет центральную роль в теоретическом анализе линейных бандитов, поскольку она гарантирует, что агент в долгосрочной перспективе выявляет «правильную» структуру зависимости награды от признаков. В контексте рассматриваемой мультиагентной системы это означает, что агенты постепенно обучаются правильно оценивать, какие стратегии (или типы взаимодействия) дают наибольшую выгоду, а какие — менее эффективны, даже при ограниченной и зашумлённой информации.

Для алгоритма LinUCB, основанного на верхних доверительных границах, доказана следующая граница кумулятивного регрета [4, 32]:

$$R(T) \leq C \cdot d\sqrt{T \ln T}, \quad (2.24)$$

где $R(T)$ — суммарный регрет за T шагов, d — размерность вектора признаков, а C — положительная константа, зависящая от параметров задачи (например, от верхних границ на награды и нормы признаков). Эта оценка показывает, что:

- $R(T)/T \rightarrow 0$ при $T \rightarrow \infty$, что означает, что средняя награда агента асимптотически стремится к оптимальной; агент не только «выживает» в среде, но и выравнивается по уровню производительности с оракулом, знающим истинные параметры $\boldsymbol{\theta}^*$;

- регрет растёт линейно с увеличением числа признаков d , что отражает естественный компромисс между сложностью модели и скоростью обучения: чем выше размерность признакового пространства, тем труднее агенту быстро выявить истинную структуру зависимости награды от признаков;
- граница не зависит от числа доступных действий K [38], что является ключевым преимуществом линейных бандитов по сравнению с табличными постановками, где регрет обычно логарифмически зависит от числа действий.

Такой вид границы делает LinUCB особенно привлекательным для задач, где агенты должны выбирать стратегии из большого или даже бесконечного множества действий (например, выбор элемента каталога, варианта контента или точки в непрерывном пространстве рекомендаций). В подобных ситуациях представление через линейные признаки и использование регрета, зависящего лишь от размерности d , позволяет эффективно обобщать опыт между действиями и избегать комбинаторного взрыва, связанного с ростом K .

Для байесовского подхода, реализованного в LinTS, граница регрета имеет аналогичную структуру, но с дополнительной зависимостью от числа действий:

$$R(T) \leq C' \cdot d\sqrt{T \ln K \ln T}, \quad (2.25)$$

где C' — другая константа, зависящая от параметров задачи [7]. Здесь появляется множитель $\sqrt{\ln K}$, который отражает тот факт, что в Thompson Sampling агент опирается на вероятностное распределение и статистическое распределение действий, и его эффективность зависит от размера пространства выбора даже при линейной структуре награды. Тем не менее, при разумно большом числе действий и умеренной размерности d этот алгоритм часто демонстрирует на практике более низкий регрет, чем LinUCB, благодаря гибкому балансу между исследованием и эксплуатацией.

2.5. Проведение экспериментов

Параметры проведённых экспериментов представлены в таблице 2.1. Эта таблица задаёт базовую структуру экспериментальной среды, в рамках которой оценивались различные алгоритмы линейных бандитов.

Таблица 2.1 – Параметры экспериментальной среды

Параметр	Значение
Количество действий (собеседников)	$K = 10$
Размерность пространства признаков	$d = 7$
Распределение признаков	$\text{Uniform}[-1, 1]^d$
Истинные веса	$\mathbf{w}^* \sim \mathcal{N}(0, \mathbf{I}_d)$
Шум наблюдений	$\varepsilon_t \sim \mathcal{N}(0, 0.1^2)$
Маска признаков	$m_i = \mathbb{I}(x_i > 0.1)$

В эксперименте используется синтетическая постановка, которая имитирует ситуацию, когда агент выбирает одного из $K = 10$ собеседников (или типов взаимодействия) на основе вектора признаков размерности $d = 7$. Вектор признаков для каждого действия a выбирается равномерно и независимо из гиперкуба $[-1, 1]^d$, что обеспечивает достаточно разнообразный набор контекстов при фиксированной и относительно небольшой размерности пространства. Истинный вектор весов $\mathbf{w}^*$, определяющий линейную зависимость награды от признаков, сэмплируется из стандартного нормального распределения $\mathcal{N}(0, \mathbf{I}_d)$, чтобы обеспечить случайную, но нетривиальную структуру взаимодействия между признаками и наградой. Наблюдаемая награда моделируется как линейная комбинация признаков с добавлением независимого гауссовского шума с нулевым средним и дисперсией 0.1^2 , что отражает реалистичный уровень зашумлённости данных в социальных и рекомендательных системах. В рамках некоторых экспериментов также используется маска признаков $m_i = \mathbb{I}(|x_i| > 0.1)$, которая позволяет анализировать влияние «активных» признаков, значительно отличающихся от нуля, на поведение агентов.

В эксперименте участвовали три алгоритма, представляющих основные подходы к исследованию в линейных бандитах:

- **LinUCB** [4, 32]: алгоритм с доверительными интервалами на основе Ridge-регрессии. Параметры: $\beta = 2.0$ (ширина доверительного интервала), $\lambda = 1.0$ (параметр регуляризации).

- **ϵ -жадный**: базовая стратегия со случайным исследованием. Параметры: $\epsilon \in \{0.1, 0.3\}$, $\alpha = 0.01$.
- **Thompson Sampling**: байесовский подход с сэмплированием из апостериорного распределения. Использовалась нормальная аппроксимация с инкрементальным обновлением статистик.

Все алгоритмы инициализировались нулевыми весами $\hat{\mathbf{w}}_0 = \mathbf{0}$, что отражает отсутствие априорных предпочтений агента в начале обучения, и использовали одинаковую скорость обучения $\alpha = 0.01$ для обеспечения сопоставимых условий сравнения. Это позволило абстрагироваться от влияния начальных условий и фокусироваться на различиях в стратегиях выбора действий и обновления оценок. Каждый эксперимент повторялся $M = 250$ независимых запусков с различными случайными седами и экземплярами $\mathbf{w}^*$, чтобы обеспечить статистическую устойчивость результатов и корректно оценить стандартные отклонения по серии запусков.

Для каждого алгоритма отслеживались следующие метрики на каждом шаге t :

$$e_t^{\text{weight}} = \|\hat{\mathbf{w}}_t - \mathbf{w}^*\|_2 \quad \text{— ошибка оценки весов,} \quad (2.26)$$

которая измеряет евклидово расстояние между текущей оценкой параметров $\hat{\mathbf{w}}_t$ и истинным вектором $\mathbf{w}^*$. Эта величина является ключевой характеристикой того, насколько быстро и точно алгоритм восстанавливает истинную структуру зависимости награды от признаков. В рамках теории линейных бандитов ожидается, что при выполнении условий сходимости эта ошибка должна уменьшаться со временем и асимптотически стремиться к нулю, хотя скорость спада зависит от стратегии выбора действий и параметров.

Кроме того, на каждом шаге вычислялась средняя ошибка предсказания наград:

$$e_t^{\text{pred}} = |\hat{y}_t - y^*| = \frac{1}{K} \sum_{a=1}^K |\hat{r}_{t,a} - \mathbf{w}^* \cdot \mathbf{x}_a| \quad \text{— средняя ошибка предсказания наград.} \quad (2.27)$$

Здесь $\hat{r}_{t,a} = \hat{\mathbf{w}}_t^\top \mathbf{x}_a$ — прогноз награды для действия a на основе текущей оценки весов, а $\mathbf{w}^* \cdot \mathbf{x}_a$ — истинное среднее значение награды. Эта метрика позволяет оценить, насколько хорошо модель агента обобщает на все возможные действия, а не только на уже

выбранные, и показывает, насколько агент «понимает» контекст пространства признаков в целом. В частности, даже если агент выборочно исследует лишь часть действий, хорошая обобщающая способность модели должна приводить к уменьшению средней ошибки по всему множеству стратегий.

На рисунках 2.1 и 2.2 продемонстрированы ошибки оценки весов и средняя ошибка предсказаний для каждого алгоритма соответственно.




Рисунок 2.1 – Динамика ошибки оценки весов $\|\hat{w}_t - w^*\|_2$ для различных алгоритмов линейных бандитов

Лучшую скорость сходимости предсказаний наград показывает LinUCB, однако для этого алгоритма сходимость весов оказывается наихудшей. Это наглядно демонстрирует тот факт, что перед алгоритмом многорукого бандита стоит задача именно минимизации ошибки предсказаний наград, а не точное угадывание весов. В частности, в случае LinUCB такой результат получается из-за смещения математического ожидания в результате применения Ridge регрессии. Если важно приблизиться к настоящим весам, то из рассмотренных алгоритмов следует выбрать жадный с $\epsilon = 0.3$. Вначале он немного уступает Thompson Sampling, но в конечном итоге лучше всех справляется с предсказанием весов и второй после LinUCB в предсказании наград.




Рисунок 2.2 – Динамика средней ошибки предсказания наград для различных алгоритмов линейных бандитов

Полученные результаты показывают, что контекстные алгоритмы способны эффективно использовать признаки среды в одиночной задаче. Однако в мультиагентной сети контекст может стать коррелированным и избыточным, поэтому в главе 5 отдельно проверяется, сохраняется ли преимущество контекстного обучения на графах.

Глава 3 Интеграция МАВ-алгоритмов в модели формирования мнений

Формирование общественного мнения — это сложный, многоэтапный процесс, формируемый непрерывными взаимодействиями между индивидами, СМИ и общественными институтами. В цифровую эпоху эти взаимодействия опосредованы в масштабе онлайн-платформами, что порождает огромные объемы поведенческих и текстовых данных [9]. Такие данные отражают коллективные настроения, поляризацию и влияние информационных потоков на общество. Изучение этих механизмов необходимо для понимания того, как меняется общественное мнение в современных информационных средах.

В данной работе формирование общественного мнения рассматривается как результат *стратегического обучения*: взаимодействующие агенты намеренно выбирают партнеров по коммуникации, чтобы стабилизировать свои собственные убеждения. В отличие от классических моделей динамики мнений, агенты при этом подходе не являются пассивными получателями социального влияния; вместо этого они являются адаптивными субъектами, принимающими решения в условиях неопределенности.

Для моделирования социальной динамики, лежащей в основе формирования мнений, было предложено множество подходов. Эти модели можно условно сгруппировать в соответствии с их предположениями о том, как агенты взаимодействуют и обновляют убеждения.

Ранние модели обычно фокусируются на достижении консенсуса через социальное влияние. Модель голосования (voter model) описывает, как случайно выбранный агент перенимает мнение случайно выбранного соседа [24]. q -модель голосования (q -voter model) расширяет эту идею, позволяя агенту изменить мнение, только если по крайней мере q соседей придерживаются иного мнения [5]. Модель ДеГрута (DeGroot model) предполагает непрерывное обновление, при котором каждый агент формирует взвешенное среднее мнений соседей [19]. Большая психологическая реалистичность вносится моделью Фридкина-Джонсена (Friedkin–Johnsen model), где агенты остаются

привязанными к своим первоначальным убеждениям, одновременно подвергаясь влиянию других [42]. Эффекты отталкивания и усиления мнений изучались в моделях с антагонистическими взаимодействиями [8].

Другие направления работ опираются на разные дисциплины или стремятся к созданию унифицированных фреймворков. Эпидемиологические модели (например, SIR) используются для представления состояний осведомленности и распространения информации [17]. Модели, ослабляющие строгие предположения о рациональном выборе, включают ценности, интуитивное обучение и обдумывание, часто формализуемые через репликаторную динамику [22]. Физические аналогии рассматривают агентов как взаимодействующие частицы, где мнения эволюционируют через правила, подобные столкновениям [35]. Унифицированные фреймворки, такие как предложенный Козицыным в [28], воспроизводят разнообразное поведение через выбор параметров. Недавно Козицын [29] представил модель SCARDO — агент-ориентированную вероятностную модель, в которой изменения мнений следуют стохастическим переходам, заданным таблицей влияния; вероятность обновления зависит от текущих мнений обоих собеседников.

Современные методы на основе машинного обучения и нейронных сетей также становятся все более важными для исследований общественного мнения. Они позволяют обрабатывать большие разнородные наборы данных и могут моделировать сложное стратегическое поведение в информационных средах. Например, Окава и Ивата [36] предложили социологически информированную нейронную сеть, которая предсказывает изменения мнений, одновременно подчиняясь управляющим уравнениям из классических моделей через дополнительный штрафной член на основе ОДУ.

Центральная проблема в онлайн-информационных экосистемах — принятие решений в условиях неопределенности: субъекты (например, новостные издания или инфлюенсеры) должны выбирать стратегии распространения информации, не зная реакции аудитории или действий конкурентов. Фреймворк "Многорукий бандит" (MAB) хорошо подходит для этого контекста, так как формализует компромисс между исследованием и эксплуатацией (exploration–exploitation trade-off). Распространенные алгоритмы включают ϵ -greedy, Upper Confidence Bound (UCB) и Thompson Sampling.

В многоагентных средах выигрыши зависят от выбора других агентов, что создает конкурентную среду. MAB-подход поддерживает анализ адаптивного поведения,

возникающих коллективных паттернов и равновесных исходов в конкуренции за внимание [49, 51]. Ван [46] установил соответствие между некоторыми моделями мнений и принципами многоруких бандитов. Синь и др. [48] использовали бандитские алгоритмы для выбора подходящих моделей обновления мнений (например, ДеГрута против Фридкина-Джонсена) на основе данных.

Несмотря на значительный прогресс в теоретико-игровом моделировании, обучении с помощью многоруких бандитов (МAB) и классической динамике мнений, их интеграция в единый фреймворк для коллективного формирования мнений остается ограниченной. Существующие подходы часто действуют в отдельных парадигмах: теория игр обычно предлагает анализ равновесия при сильных предположениях о рациональности, тогда как МAB-модели описывают индивидуальное адаптивное обучение в условиях неопределенности.

В частности, отсутствует систематический анализ того, как популяции гетерогенных, стратегически обучающихся агентов — каждый из которых использует МAB-алгоритм для оптимизации поведения в конкурентной экономике внимания — формируют макро-результаты, предсказываемые моделями динамики мнений.

3.1. Методы

Изменение мнения агента зависит от его собственного текущего мнения x_1 и от мнения x_2 агента, с которым он взаимодействует. После взаимодействия мнение агента может принять значение, отличное от x_1 и x_2 (Рис. 3.1).




Рисунок 3.1 – Схема изменения мнения агента во время взаимодействия

Перед каждым новым взаимодействием агент выбирает другого агента для взаимодействия, основываясь на своем текущем сформированном мнении об агентах и целях, которые он преследует. После взаимодействия агент определяет величину выгоды, которую он получил в результате взаимодействия. Эта выгода формирует новое мнение об агенте, с которым он взаимодействовал. Схема этого процесса показана на Рисунке 3.2.




Рисунок 3.2 – Схема обновления мнения после взаимодействия

Таким образом, ожидаемая награда $u(x_i)$ от взаимодействия с агентом, имеющим мнение x_i , меняется со временем t . Следовательно, выбор агентов для взаимодействия также меняется, и, как следствие, меняется и мнение самого агента (Рис. 3.3).




Рисунок 3.3 – Изменение мнения агента вследствие изменения ожиданий

Чтобы заложить основу для нашего анализа, мы начинаем с рассмотрения модели динамики мнений, предложенной Козицыным [29]. Модель концептуализирует систему, состоящую из N агентов. Каждый агент i характеризуется мнением $x_i(t)$, которое принадлежит дискретному множеству возможных мнений $Z = \{z_1, \dots, z_m\}$. Ядром мо-

дели является вероятностный механизм обновления мнения под социальным влиянием. Когда агент j (влияющий) взаимодействует и пытается повлиять на агента i (влияемый), новое мнение последнего определяется не детерминированно. Вместо этого оно извлекается из распределения вероятностей, которое зависит от текущих мнений обоих участников взаимодействия. Формально, если агент i придерживается мнения $x_i = z_s$ и на него влияет агент j с мнением $x_j = z_l$, то обновленное мнение агента i определяется условным распределением вероятностей:

$$P_{s,l} = (p_{s,l,1}, \dots, p_{s,l,m}),$$

где значение $p_{s,l,k} \in [0, 1]$ — это вероятность перехода $z_s \rightarrow z_k$ агента i . При этом $p_{s,l,1} + \dots + p_{s,l,m} = 1$.

Все эти условные вероятности могут быть компактно организованы в таблицу переходов $\mathcal{P}$. Эту таблицу можно рассматривать как последовательность из m стохастических по строкам матриц

$$\mathcal{P} = [P_1, \dots, P_m],$$

каждая размером $m \times m$. Матрица P_s специфически кодирует профиль реакции агента, текущее мнение которого z_s : ее l -я строка предоставляет вектор вероятностей $P_{s,l}$, описывающий, как этот агент реагирует на влияние со стороны агента с мнением z_l .

Вторая модель включает концепцию упрямства агента, основываясь на классической модели Фридкина-Джонсена [25]. В этой модели обновление мнения агента больше не является чисто стохастическим, а следует правилу выпуклой комбинации:

$$x_i^{\text{new}} = \alpha \cdot x_i^{\text{old}} + (1 - \alpha) \cdot x_j,$$

где x_j — мнение агента, с которым происходит взаимодействие. Параметр $\alpha \in [0, 1]$ определяет приверженность агента своему старому мнению. Значение α , равное 1, указывает на полную негибкость (мнение никогда не меняется), в то время как $\alpha = 0$ означает полную восприимчивость, сводя обновление к простому принятию мнения влияющего лица.

Рассмотрим две возможные мотивации поведения агента.

- **Стремление остаться при своем мнении.** Выбор награды как стремления сохранить своё мнение научно обоснован устойчивостью убеждений —

люди психологически сопротивляются изменениям, поскольку это вызывает когнитивный дискомфорт и требует больших ментальных усилий.

При симуляции такой награды в случае SCARDO модели выигрыш много-рукого бандита на шаге взаимодействия k определяется как отрицательное абсолютное изменение его собственного мнения:

$$u_k = -|z_p - z_q|,$$

где z_p — мнение агента на шаге k , z_q — мнение агента на шаге $k - 1$.

В случае модели Фридкина-Джонсена выигрыш на k -м шаге вычисляется следующим образом:

$$u_k = -|x_i^{\text{new}} - x_i^{\text{old}}|.$$

- **Стремление приблизиться к внешней истине.** Примером внешней истины можно считать математическое ожидание некоторой случайной величины. Таким образом, агенту выгодно знать данное значение, так как на его основе он может принимать более рациональные решения относительно событий, на которые данная случайная величина влияет.

Выигрыш при стремлении агента приблизиться к внешней истине θ на шаге k для SCARDO модели вычисляется как:

$$u_k = -|z_k - \theta|,$$

где z_k — мнение агента на шаге k .

А для модели Фридкина-Джонсена:

$$u_k = -|x_i^{\text{new}} - \theta|.$$

Для выбора собеседника рассмотрены три стратегии: ϵ -greedy, UCB, Thompson Sampling.

3.2. Проведение экспериментов

Наш эмпирический анализ опирается на существующий крупномасштабный набор данных о политических мнениях в социальной сети ВКонтакте, первоначально собранный и проанализированный в [29]. Набор данных фиксирует политические позиции

пользователей в три различных момента времени в течение 2018 года — февраль, июль и декабрь — что позволяет изучать временные изменения в выражаемых взглядах. Полный набор данных охватывает более 1.6 миллиона пользователей и сопровождается графом, построенным на основе наблюдений, сделанных в июле 2018 года.

Политическая ориентация каждого пользователя закодирована как непрерывное числовое значение от 0 до 1, где более низкие значения указывают на оппозицию властям, а более высокие значения соответствуют провластной позиции. Чтобы обеспечить связность сети и согласованность с предыдущими работами, мы следуем стратегии фильтрации [29] и оставляем только пользователей, принадлежащих к наибольшей связной компоненте графа. Эта компонента содержит примерно 99% всех пользователей в исходной сети, в то время как изолированные узлы и небольшие несвязные компоненты отбрасываются.

Работа Козицына обеспечивает эмпирическое обоснование для симуляций, выводя реалистичные вероятностные матрицы переходов для случая $m = 5$ дискретных мнений из реальных данных социальной сети (ВКонтакте) (Рис. 3.4). Эти матрицы составляют стохастическую среду, в которой действуют МАВ-агенты.

Было проведено $N = 250$ экспериментов с одинаковыми входными параметрами для статистического анализа. Каждый эксперимент проводился на полном графе с 7 потенциальными собеседниками, результаты анализировались за первые $t = 100$ шагов. На рисунке 3.5 представлены средняя накопленная награда и среднее мнение агента по всем симуляциям, а также относительно средних значений отложено по одному стандартному отклонению.

Результаты алгоритмов SCARDO модели не показали значимых отличий в накопленной награде при стремлении агента остаться при своем мнении. Также, после проведения экспериментов с разными значениями внешней истины не выявлена разница между алгоритмами. Это может быть связано с тем, что в матрицах перехода высокая вероятность остаться при своем мнении, практически независимо от того, с кем агент взаимодействует.

На рисунке 3.6 рассматривается сценарий, учитывающий упрямство агента ($\alpha = 0.3$). Начальное мнение каждого агента задается случайным образом и принадлежит ин-

0.947	0.044	0.008	0.001	0
0.954	0.04	0.006	0	0
0.938	0.051	0.01	0.001	0
0.911	0.07	0.016	0.003	0
0.919	0.063	0.009	0.009	0

(a) Матрица P_1

0.055	0.872	0.071	0.002	0
0.046	0.898	0.055	0.001	0
0.032	0.893	0.073	0.002	0
0.04	0.859	0.097	0.004	0
0.047	0.858	0.092	0.003	0

(b) Матрица P_2

0.002	0.057	0.919	0.022	0
0.002	0.052	0.95	0.011	0
0.001	0.038	0.943	0.018	0
0.001	0.039	0.913	0.046	0.001
0.001	0.043	0.896	0.059	0.001

(c) Матрица P_3

0.001	0.002	0.102	0.876	0.019
0.001	0.005	0.093	0.886	0.015
0	0.002	0.078	0.905	0.015
0.001	0.002	0.068	0.898	0.031
0.001	0.003	0.069	0.884	0.043

(d) Матрица P_4

0	0	0.011	0.097	0.892
0	0.003	0.009	0.081	0.907
0.001	0.001	0.006	0.072	0.92
0	0.001	0.006	0.069	0.924
0.001	0	0.005	0.071	0.923

(e) Матрица P_5

Рисунок 3.4 – Матрицы переходов $P_1, \dots, P_m$ для модели SCARDO при $m = 5$




Рисунок 3.5 – Результаты экспериментов на модели SCARDO: средняя накопленная награда (слева) и среднее мнение агента (справа) для различных бандит-алгоритмов




Рисунок 3.6 – Результаты экспериментов на модели Фридкина-Джонсена с параметром упрямства $\alpha = 0.3$

тервалу $[0, 1]$. В этом случае ситуация меняется на противоположную. Здесь ϵ -жадный алгоритм значительно превосходит два других.

Проверим статистическую значимость этого результата. После множественных симуляций были проведены тесты Шапиро-Уилка на нормальность, Левена на однородность дисперсий и t-тест Уэлча для попарных сравнений стратегий.

Таблица 3.1 – Результаты теста Шапиро-Уилка на нормальность распределения

Стратегия	W-статистика	p-value
ϵ -greedy	0.9606	0.0942
UCB	0.9770	0.4353
Thompson	0.9798	0.5424

Результаты теста Шапиро-Уилка представлены в Таблице 3.1. Для всех стратегий $p\text{-value} > 0.05$. Следовательно, гипотеза о нормальности распределения для каждой из стратегий не может быть отвергнута на уровне значимости $\alpha = 0.05$.

Результаты теста Левена показали статистически значимые различия между групповыми дисперсиями: $F = 9.1864$, $p < 0.001$. Отсюда гипотеза о равенстве дисперсий отвергается на уровне значимости $\alpha = 0.05$.

Из результатов Таблицы 3.2 видно, что на уровне значимости 0.05 разница между накопленным выигрышем любой пары алгоритмов статистически значима.

Таблица 3.2 – Сравнение стратегий с использованием теста Уэлча

Сравнение	Статистика теста	p-value
ϵ -greedy vs UCB	20.9468	< 0.0001
ϵ -greedy vs Thompson	20.9835	< 0.0001
UCB vs Thompson	-2.0338	0.0447




Рисунок 3.7 – Результаты модели Фридкина-Джонсена с внешней истиной $\theta = 0.8$

Рисунок 3.7 демонстрирует поведение стратегий в модели Фридкина-Джонсена с внешней истиной $\theta = 0.8$. Наилучшие результаты вновь показывает ε -жадный алгоритм. Однако стоит заметить, что ни одному из алгоритмов не удалось достичь истинного значения.

В таблице 3.3 приведены статистические результаты теста на нормальность. Для каждой стратегии $p\text{-value} < 0.05$, следовательно, гипотеза о нормальности распределения отвергается на уровне значимости 0.05. Тест Левена на равенство дисперсий имеет значение статистики 25.21 и $p\text{-value} = 0.00$, что говорит о разных дисперсиях между группами. Исходя из этих данных, для сравнения средних накопленных выигрышей использовался Mann–Whitney U тест. Результаты приведены в таблице 3.4.

Таблица 3.3 – Результаты теста Шапиро-Уилка на нормальность распределения
(внешняя истина $\theta = 0.8$)

Стратегия	W-статистика	p-value
ε -greedy	0.8537	0.0000
UCB	0.9654	0.0001
Thompson	0.9446	0.0000

Таблица 3.4 – Парные сравнения стратегий (Mann–Whitney U тест) для $\theta = 0.8$

Сравнение	U-статистика	p-value
ε -greedy vs UCB	38048.0000	0.0000
ε -greedy vs Thompson	37054.0000	0.0000
UCB vs Thompson	15484.0000	0.0001

Парное сравнение средних накопленных выигрышей с помощью Mann–Whitney U теста показало статистически значимое различие между любыми парами алгоритмов на уровне значимости 0.05.

В случае низкого значения внешней истины ситуация аналогична (рис. 3.8).




Рисунок 3.8 – Результаты модели Фридкина-Джонсена с низким значением внешней истины ($\theta = 0.2$)

Глава 4 Мультиагентная динамика мнений на разреженных графах

В предыдущих главах рассматривались фрагменты модели динамики мнений: контекстные многорукие бандиты (Contextual Bandits) без привязки к графовой структуре и неконтекстные бандиты в полном графе с перспективы одного агента. Данные подходы выявили эффективность алгоритмов в балансе исследования и эксплуатации, но не учли реалистичные сценарии разреженных сетей с локальными взаимодействиями.

Настоящая глава синтезирует эти результаты в единую мультиагентную модель на неполном графе, где все агенты одновременно выбирают действия, влияющие на их мнения через соседей. Каждый агент применяет МАВ-алгоритмы — без контекста и с контекстом. Такой подход позволяет сравнить регрет, скорость сходимости и влияние контекста на коллективную динамику.

4.1. Логика функционирования агента

Каждый агент в модели обладает мнением, представленным вещественным числом в диапазоне $[0, 1]$. На каждом временном шаге t агент i выбирает одну из пяти возможных стратегий обновления своего мнения $x_i(t)$:

1. **Стратегия 0 (Stubborn)**: мнение агента не изменяется:

$$x_i(t+1) = x_i(t)$$

2. **Стратегия 1 (Average)**: мнение полностью заменяется на среднее арифметическое мнений его соседей:

$$x_i(t+1) = \frac{1}{|N(i)|} \sum_{j \in N(i)} x_j(t)$$

3. **Стратегия 2 (Compromise)**: мнение смещается на 30% в сторону среднего мнения соседей:

$$x_i(t+1) = (1 - \alpha)x_i(t) + \alpha \bar{x}_{N(i)}(t), \quad \alpha = 0.3$$

4. **Стратегия 3 (Drift Up)**: мнение увеличивается на $\delta = 0.05$, если не превышает 0.95:

$$x_i(t+1) = \min(x_i(t) + 0.05, 0.95)$$

5. **Стратегия 4 (Drift Down)**: мнение уменьшается на $\delta = 0.05$, если не ниже 0.05:

$$x_i(t+1) = \max(x_i(t) - 0.05, 0.05)$$

В варианте данного моделирования не используется выигрыш, который стимулирует агента остаться при своем мнении, так как эта возможность уже представлена в виде отдельной стратегии. Поэтому выигрыш направлен на приближение к внешней истине θ :

$$r_i(t) = -|x_i(t+1) - \theta|$$

Таким образом, задача каждого агента сводится к максимизации награды через выбор наиболее подходящей стратегии обновления.

4.2. Реализация алгоритмов обучения

Для выбора стратегии агентом используются два класса алгоритмов обучения с подкреплением.

Контекстно-свободные алгоритмы не используют информацию о состоянии агента и среды. В рамках исследования были реализованы три алгоритма:

- **ε -greedy**: с вероятностью ε выбирает случайную стратегию, иначе — стратегию с максимальной оценкой $\hat{Q}_a$:

$$a_t = \begin{cases} \arg \max_a \hat{Q}_a, & \text{с вероятностью } 1 - \varepsilon \\ \text{случайная } a, & \text{с вероятностью } \varepsilon \end{cases}$$

- **UCB (Upper Confidence Bound)**: балансирует между исследованием и эксплуатацией за счет добавления доверительного интервала к оценке стратегии:

$$a_t = \arg \max_a \left(\hat{Q}_a + c \sqrt{\frac{\ln t}{n_a}} \right)$$

- **Thompson Sampling**: выбирает стратегию на основе выборки из нормального распределения, параметры которого обновляются с каждым шагом:

$$\tilde{Q}_a \sim \mathcal{N}(\hat{Q}_a, \sigma_a^2)$$

Контекстные алгоритмы дополняют базовый подход, добавляя данные о состоянии агента и соседей при выборе действия. В модели агент i в момент времени t использует контекстный вектор $\mathbf{c}_i(t) \in \mathbb{R}^4$, отражающий личные и локальные свойства графа. Вектор состоит из четырех признаков:

$$\mathbf{c}_i(t) = \begin{bmatrix} 1 & x_i(t) & |x_i(t) - \theta| & \text{Var}(\{x_j(t)\}_{j \in N(i)}) \end{bmatrix}^T,$$

Компоненты вектора:

1. 1 – константа для базового уровня в модели награды.
2. $x_i(t)$ – текущее положение агента на шкале мнений.
3. $|x_i(t) - \theta|$ – расстояние мнения до цели θ , стимулирующее выбор сближающих действий.
4. $\text{Var}(\{x_j(t)\}_{j \in N(i)})$ – разброс мнений соседей.

Для работы с контекстом были реализованы следующие алгоритмы:

- **Linear ε -greedy**: использует линейную оценку полезности стратегии $\hat{Q}_a(\mathbf{c}) = \mathbf{c}^T \boldsymbol{\theta}_a$;
- **LinUCB**: добавляет доверительный интервал к линейной оценке:

$$a_t = \arg \max_a \left(\mathbf{c}_t^T \hat{\boldsymbol{\theta}}_a + \alpha \sqrt{\mathbf{c}_t^T \mathbf{A}_a^{-1} \mathbf{c}_t} \right)$$

- **Linear Thompson Sampling**: выполняет выборку из многомерного нормального распределения параметров модели.

Все алгоритмы работают в онлайн-режиме, обновляя свои внутренние параметры после каждого взаимодействия агента со средой.

4.3. Топологии социальных сетей

Модель Эрдёша-Реньи [21], появившаяся в 1959 году, заложила основы теории случайных графов и до сих пор служит эталоном для тестирования алгоритмов. Чтобы построить граф $G(N, p)$, берётся множество из N узлов, и для каждой из $\binom{N}{2}$ пар

независимо проводится ребро с вероятностью $p \in [0, 1]$. При $p = 0$ получается пустой граф, а при $p = 1$ — полный. Существует также вариант $G(N, M)$, где число рёбер M фиксировано и распределяется равномерно.

Эта модель демонстрирует фазовый переход при средней степени $\langle k \rangle = (N-1)p = 1$: ниже этой отметки граф распадается на малые компоненты, выше — появляется гигантское связное подмножество. Распределение степеней узлов задаётся формулой:

$$P(k) = \binom{N-1}{k} p^k (1-p)^{N-1-k}, \quad (4.1)$$

которая при $N \rightarrow \infty$ и фиксированном $\langle k \rangle$ переходит в пуассоновское. Кластеризация остаётся низкой и равна примерно $C \approx \frac{\langle k \rangle}{N}$. В связной компоненте средняя длина пути выражается как:

$$L \approx \frac{\ln N}{\ln \langle k \rangle}. \quad (4.2)$$

Модель Барабаши-Альберта [11] от 1999 года объясняет наблюдаемый в реальности закон степенных распределений в сетях, цитирований статей или социальных контактов. Процесс роста начинается с малого графа из m_0 узлов. Затем последовательно добавляются новые узлы, каждый из которых соединяется с $m \leq m_0$ существующими, выбирая их с вероятностью, пропорциональной текущей степени:

$$\Pi(k_i) = \frac{k_i}{\sum_j k_j}. \quad (4.3)$$

В итоге формируется безмасштабная сеть с $P(k) \sim k^{-\gamma}$, где $\gamma = 3 + m/m_0 \approx 3$. Такие сети богаты хабами, которые доминируют в распространении информации. Диаметр растёт очень медленно как $L \sim \ln N / \ln \ln N$. Кластеризация $C \sim (\ln N)/N$ ниже, чем в реальных социальных сетях, но существенно выше, чем в случайных графах.

Модель Ватса-Строгаца [47] 1998 года решает классическую задачу small-world: как совместить высокую локальную кластеризацию с короткими глобальными путями, как в знакомом эффекте «шести рукопожатий». Алгоритм начинается с регулярного кольца из N узлов, где каждый соединён с k ближайшими соседями ($k \ll N$, чётное). Затем каждое из $Nk/2$ рёбер переподключается к случайному узлу с вероятностью $p \in [0, 1]$, избегая самопетель.

Модель плавно переходит между режимами: при $p = 0$ это идеальное кольцо с $C(0) = 3(k-2)/(4(k-1)) \approx 3/4$, но длинными путями $L(0) \approx N/(2k)$. При $p = 1$

получается аналог Эрдёша-Реньи с $C(1) \approx k/N$ и $L(1) \approx \ln N / \ln k$. Оптимальный small-world эффект достигается при $0.01 \leq p \leq 0.1$, где кластеризация почти не падает — $C(p) \approx C(0)$ — при длине пути $L(p) \approx L(1)$.

Таблица 4.1 – Сравнение моделей синтетических сетей

Модель	ER	BA	WS
Распределение степеней	Пуассона	Степенное	Узкое
Коэффициент кластеризации	Низкий	Средний	Высокий
Средняя длина пути	Короткая	Очень короткая	Короткая
Наличие хабов	Нет	Да	Нет
Гомофилия	Нет	Частичная	Сильная

Для целей данного исследования все три модели позволяют устранить ограничение полного графа и изучить, как топология социальных связей влияет на эффективность стратегического обучения агентов. Множество доступных партнёров для агента i в синтетической сети ограничивается его соседями:

$$\mathcal{A}_t^{(i)} = \{j \mid (i, j) \in E\}, \quad (4.4)$$

где E — множество рёбер графа $G = (V, E)$.

4.4. Проведение симуляции

Каждый вычислительный эксперимент состоит из серии запусков $K = 10$ для повышения статистической достоверности. В рамках одного запуска выполняется $T = 300$ временных шагов, в течение которых $N = 50$ агентов последовательно обновляют свои мнения. Для каждого алгоритма регистрируются средние значения мнений, накопленная награда, а также частота использования каждой из пяти стратегий.

4.5. Сводные результаты экспериментов

В таблицах 4.2–4.7 представлены агрегированные результаты симуляций для трёх типов синтетических графов. Все значения усреднены по $M = 250$ независимым запускам.




Рисунок 4.1 – Динамика среднего мнения агентов в графе Эрдёша-Реньи для различных алгоритмов




Рисунок 4.2 – Пример конечных мнений для одной из реализаций в графе Эрдёша-Реньи




Рисунок 4.3 – Динамика среднего мнения агентов в графе Барабаши-Альберта для различных алгоритмов




Рисунок 4.4 – Пример конечных мнений для одной из реализаций в графе Барабаши-Альберта




Рисунок 4.5 – Динамика среднего мнения агентов в графе Ватса-Строгаца для различных алгоритмов




Рисунок 4.6 – Пример конечных мнений для одной из реализаций в графе Ватса-Строгаца

Таблица 4.2 – Результаты для графа Эрдёша-Реньи (ER)

Алгоритм	Мнение	SE	Награда	Ошибка
UCB	0.8006	0.0022	-25.04	0.0006
Lin- ϵ -greedy	0.7841	0.0044	-24.28	0.0159
Thompson	0.7668	0.0149	-32.08	0.0332
Lin-Thompson	0.7594	0.0102	-35.16	0.0406
ϵ -greedy	0.8969	0.0104	-43.09	0.0969
LinUCB	0.6293	0.0091	-64.44	0.1707

Таблица 4.3 – Распределение стратегий по алгоритмам (среднее за все запуски) для графа ER

Алгоритм	Stubborn	Average	Compromise	+0.05	-0.05
ucb	2990.5	3232.4	3108.8	2996.5	2671.8
lin_epsilon_greedy	729.4	7254.9	2088.3	3466.2	1461.2
thompson	2973.4	3116.5	3026.1	3122.5	2761.5
lin_thompson	2986.7	2998.6	2983.9	3123.8	2907.0
epsilon_greedy	740.8	5055.8	2440.0	5960.4	803.0
linucb	2920.3	2877.0	2866.4	3258.2	3078.1

4.6. Анализ результатов

Таблицы раскрывают картину производительности алгоритмов в разреженных сетях. В графе Эрдёша-Реньи (ER, табл. 4.2, 4.3) UCB лидирует по точности сходимости к $\theta \approx 0.8$: среднее мнение 0.8006 при минимальной ошибке 0.0006 и стандартной ошибке SE=0.0022, награда -25.04. Контекстный Lin- ϵ -greedy показывает очень неплохой результат: среднее мнение 0.7841, при этом достигается лучшая накопленная награда (-24.28) среди всех алгоритмов в ER, что говорит о высокой эффективности в части оптимизации вознаграждения, хотя стабильность ниже, чем у UCB. Контекстные LinUCB и Lin-Thompson выглядят значительно хуже (ошибки 0.1707 и 0.0406), что указывает на неудачное использование контекста и склонность к переобучению. Неконтекстные ϵ -greedy и Thompson демонстрируют стабильную, но менее точную динамику, с заметным разбросом конечных мнений.

Таблица 4.4 – Результаты для графа Барабаши-Альберта (ВА)

Алгоритм	Мнение	SE	Награда	Ошибка
UCB	0.8053	0.0032	-25.46	0.0053
Lin- ϵ -greedy	0.7882	0.0045	-22.91	0.0118
Thompson	0.7716	0.0093	-32.30	0.0284
Lin-Thompson	0.7449	0.0122	-35.88	0.0551
ϵ -greedy	0.8969	0.0151	-42.12	0.0969
LinUCB	0.6210	0.0069	-66.14	0.1790

Таблица 4.5 – Распределение стратегий по алгоритмам (среднее за все запуски) для графа ВА

Алгоритм	Stubborn	Average	Compromise	+0.05	-0.05
ucb	2986.8	3300.4	3124.3	2942.5	2646.0
lin_epsilon_greedy	719.1	6988.6	2413.1	3593.8	1285.4
thompson	2978.1	3109.9	3014.4	3115.6	2782.0
lin_thompson	2979.4	2992.3	2987.1	3138.8	2902.4
epsilon_greedy	757.2	5166.0	2378.2	5900.7	797.9
linucb	2925.4	2874.7	2863.9	3264.5	3071.5

Аналогичная картина наблюдается в графе Барабаши–Альберта (ВА, табл. 4.4, 4.5): UCB по-прежнему доминирует по точности (0.8053, ошибка 0.0053), а контекстный Lin- ϵ -greedy снова оказывается одним из лучших по награде (-22.91). Хабы ВА усиливают локальные влияния, но контекстные алгоритмы, кроме Lin- ϵ -greedy, в целом не оправдывают включения контекста, а LinUCB снова показывает высокую ошибку (0.1790). Неконтекстный ϵ -greedy чаще всего выбирает стратегию Drift Up (+0.05, около 5900 выборов), что разгоняет коллективное мнение к 0.8969 и ухудшает точность, но частично окупается в награде.

В графе Ватса–Строгаца (WS, табл. 4.6, 4.7) с высокой локальной кластеризацией UCB сохраняет лидерство по точности (0.8035, ошибка 0.0035), а контекстный Lin- ϵ -greedy — по награде (-24.73), став лучшим в этом показателе во всех трёх сетях.

Таблица 4.6 – Результаты для графа Ватса-Строгаца (WS)

Алгоритм	Мнение	SE	Награда	Ошибка
UCB	0.8035	0.0018	-26.24	0.0035
Lin- ϵ -greedy	0.7863	0.0050	-24.73	0.0137
Thompson	0.7732	0.0123	-33.14	0.0268
Lin-Thompson	0.7575	0.0094	-36.16	0.0425
ϵ -greedy	0.8889	0.0107	-43.41	0.0889
LinUCB	0.6274	0.0106	-65.20	0.1726

Таблица 4.7 – Распределение стратегий по алгоритмам (среднее за все запуски) для графа WS

Алгоритм	Stubborn	Average	Compromise	+0.05	-0.05
ucb	2984.4	3249.2	3111.0	2986.7	2668.7
lin_epsilon_greedy	831.0	7429.8	1773.3	3594.8	1371.1
thompson	2976.7	3111.0	3015.8	3141.0	2755.5
lin_thompson	2983.4	2985.6	2982.9	3143.4	2904.7
epsilon_greedy	709.7	5043.1	2508.3	5920.3	818.6
linucb	2921.9	2879.0	2867.0	3253.9	3078.2

Локальные кластеры усиливают эффект компромисса, но контекстные алгоритмы, кроме Lin- ϵ -greedy, остаются неэффективными.

Топология слабо влияет на общий ранжир: UCB стабильно лучше всего сходится к целевому мнению во всех графах (0.8006–0.8053), а контекстный Lin- ϵ -greedy стабильно лучший по награде (–22.91 – –24.73). Остальные контекстные алгоритмы (LinUCB, Lin-Thompson) оказываются систематически хуже, демонстрируя ошибки в диапазоне 0.04–0.18. Неконтекстные алгоритмы выделяются более выраженной специализацией: UCB и Thompson равномерно разбрасывают выборы между Average (~ 3200), Compromise (~ 3100) и остальными стратегиями, тогда как контекстный Lin- ϵ -greedy и неконтекстный ϵ -greedy концентрируются на Average (5000–7400) и Drift Up (+0.05, 3500–5900), что позволяет им получать хорошую награду, но ценой отклонения от ис-

тинного значения θ . ER даёт наибольший разброс по SE, BA усиливает влияние хабов, а WS проявляет локальную стабильность (минимальный SE у UCB — 0.0018).

Эксперименты показывают, что неконтекстные алгоритмы в целом предпочтительнее в мультиагентных сценариях на разреженных графах: UCB оптимален, когда приоритет — точная сходимость коллективного мнения к истине, а контекстный Lin- ϵ -greedy выделяется тем, что наилучшим образом балансирует награду и информативность контекста, не скатываясь к переобучению, как это делают LinUCB и Lin-Thompson. Контекст ухудшает результаты других алгоритмов, вероятно, из-за того, что мнения соседей в сети часто сильно похожи друг на друга, а некоторые признаки в контекстном векторе (текущее мнение агента, разброс мнений соседей, расстояние до θ) становятся сильно коррелированными и почти избыточными. В такой ситуации линейные модели, пытающиеся выучить зависимость от этого контекста, начинают считывать шум, а более простые алгоритмы, которые накапливают среднюю награду по стратегиям, оказываются устойчивее. При этом линейный ϵ -greedy — исключение: он удачно использует контекст для агрессивного, но довольно рационального исследования, что делает его наиболее успешным контекстным алгоритмом в серии экспериментов.

Глава 5 Многорукий бандит с тяжёлыми хвостами и FunctionalUCB

5.1. Характеристика распределений с тяжёлыми хвостами

В классических работах по многорукому бандиту (многорукому бандиту, MAB) часто предполагается, что награды имеют ограниченную дисперсию или подчиняются субэкспоненциальному распределению (например, нормальное или экспоненциальное) [12, 30]. В таких условиях стандартный UCB-алгоритм [10] использует бонус вида

$$c\sqrt{\frac{\log t}{n_i(t)}},$$

основанный на оценке среднего значения награды и концентрации около среднего по типу неравенства Хёфдинга.

Однако во многих прикладных задачах, например, в финансовых временных рядах, телекоммуникациях или аномалийном сетевом трафике, наблюдаемые распределения наград имеют тяжёлые хвосты: вероятность больших выбросов убывает медленно, как степенная функция [23]. В этом случае первый момент может существовать, тогда как высшие моменты отсутствуют, и стандартные оценки среднего становятся нестабильными [15].

Класс моделей с тяжёлыми хвостами часто описывается через *индекс хвоста* $\alpha > 0$. Если распределение принадлежит домену притяжения распределения Фреше с индексом α , то хвостовая функция ведёт себя как

$$\mathbb{P}(X > x) \sim cx^{-\alpha}, \quad x \rightarrow \infty,$$

где $c > 0$ — некоторая константа [13]. В таких ситуациях асимптотическое поведение выборочных оценок и гарантированный regret для стандартного UCB ухудшаются, так как классические неравенства концентрации приходится заменять более слабыми оценками, основанными, например, на моментных ограничениях порядка α [15].

5.2. Алгоритм Functional UCB с адаптивной оценкой индекса

Хилла

Данная глава рассматривает робастный аспект обучения агента в стохастической среде. Она показывает, как выбор бандит-алгоритма должен меняться при нарушении стандартных предположений о распределении наград.

5.2.1. Постановка задачи

Рассматривается классическая задача о многоруком бандите (Multi-Armed Bandit, MAB) с набором ручек $\mathcal{K} = \{1, \dots, K\}$. Каждая ручка $i \in \mathcal{K}$ характеризуется неизвестным распределением наград F_i . В отличие от традиционных постановок, ориентированных на максимизацию математического ожидания, в данной работе рассматривается оптимизация q -квантиля распределения наград [16]:

$$Q_i(q) = \inf\{x : F_i(x) \geq q\}, \quad q \in (0, 1). \quad (5.1)$$

На каждом шаге $t = 1, 2, \dots, T$ агент выбирает ручку I_t , стремясь минимизировать накопленный квантильный регрет. Для решения задачи используется модифицированный алгоритм верхней доверительной границы (Upper Confidence Bound, UCB), адаптированный для работы в условиях распределений с «тяжелыми хвостами».

5.2.2. Оценка индекса хвоста и статистика Хилла

Для корректного построения доверительных интервалов в условиях тяжелых хвостов необходимо оценивать индекс экстремального значения γ (параметр формы распределения Парето). В данной работе используется оценка Хилла [27].

Пусть $X_{(1)} \geq X_{(2)} \geq \dots \geq X_{(n_i)}$ — порядковые статистики наград, полученных от ручки i к моменту времени t , где n_i — количество испытаний данной ручки. Оценка Хилла определяется как логарифмическое среднее превышений над порогом:

$$\hat{\gamma}_{i,t} = \frac{1}{k} \sum_{j=1}^k \ln \left(\frac{X_{(j)}}{X_{(k+1)}} \right), \quad (5.2)$$

где соответствующий индекс хвоста (параметр формы) равен $\hat{\alpha}_{i,t} = 1/\hat{\gamma}_{i,t}$.

Для повышения стабильности оценки на малых выборках и предотвращения anomalously высоких значений бонуса применяется регуляризованная (сглаженная) оценка

α_{eff} :

$$\alpha_{eff}(i, t) = \frac{k \cdot \hat{\alpha}_{i,t} + \beta \cdot \alpha_0}{k + \beta}, \quad (5.3)$$

где α_0 — априорное значение индекса хвоста, β — параметр силы регуляризации. Согласно [34], такая оценка остается асимптотически состоятельной при выполнении условий на рост k .

5.2.3. Обоснование выбора параметра $k(n)$

Выбор количества используемых верхних статистик k представляет собой классическую проблему баланса смещения и дисперсии (bias-variance tradeoff). Малые значения k ведут к высокой дисперсии из-за чувствительности к единичным выбросам, в то время как чрезмерно большие k включают данные из «тела» распределения, нарушая условие применимости степенного закона.

В теории экстремальных значений (EVT) показано, что для распределений, удовлетворяющих условию второго порядка регулярного варьирования, оптимальная скорость роста k составляет $k(n) \propto n^{\frac{2\rho}{2\rho+1}}$ [20]. В данной работе используется эвристика:

$$k(n_i) \approx n_i^{0.65}, \quad (5.4)$$

что аппроксимирует теоретический оптимум $n^{2/3}$ и обеспечивает скорость затухания ошибки оценки порядка $O(1/\sqrt{k})$.

5.2.4. Решающее правило алгоритма

На каждом шаге $t > K$ выбор ручки осуществляется на основе максимизации следующего функционала:

$$I_t = \arg \max_{i \in \{1, \dots, K\}} \left(\hat{Q}_{i,t}(q) + c \cdot \left(\frac{\ln t}{n_i} \right)^{\frac{1}{\alpha_{eff}(i,t)}} \right), \quad (5.5)$$

где $\hat{Q}_{i,t}(q)$ — эмпирический квантиль ручки i , а $c > 0$ — константа исследования. Степень $1/\alpha_{eff}$ в структуре бонуса позволяет адаптивно расширять доверительный интервал для ручек с более тяжелыми хвостами, что теоретически гарантирует сублинейный рост регрета в распределениях с неограниченной дисперсией [16].

В рассматриваемой задаче в качестве целевой характеристики награды выбран q -квантиль ($q \in (0, 1)$), а не математическое ожидание. Такой выбор обусловлен тем, что

в ряде прикладных сценариев, в частности для распределений с тяжёлыми хвостами, математическое ожидание может отсутствовать или быть бесконечным. Например, для распределения Парето с индексом хвоста $\alpha \leq 1$ и для распределения Коши математическое ожидание не определено, что делает стандартную постановку UCB, основанную на оптимизации среднего, некорректной с теоретической точки зрения.

В таких условиях квантильный подход является более универсальным: для любого распределения, не вырожденного в одну точку, существует хотя бы один из квантилей, а для непрерывных распределений подходят все уровни $q \in (0, 1)$. Оптимизация квантиля позволяет сохранить осмысленную интерпретацию стратегии даже в случае отсутствия среднего значения, а также повышает робастность алгоритма к редким, но большим выбросам в хвостах распределений. В связи с этим в дипломной работе используется квантильный критерий, а предложенный алгоритм FunctionalUCB строится как обобщение UCB-подхода на задачу оптимизации q -квантиля в условиях тяжёлых хвостов.

5.2.5. Сравнение с базовыми алгоритмами для тяжелых хвостов

В дипломной работе реализованы следующие базовые алгоритмы для сравнения с FUNCTIONALUCB:

- Classic UCB For Quantile — стандартный UCB с бонусом $\sqrt{\log t/n_i(t)}$, адаптированный для квантиля.
- Heavy Tail UCB For Quantile — UCB с фиксированным α и бонусом $(\log t/n_i(t))^{1/\alpha}$.
- BootstrapTS — алгоритм использует бутстрап-выборки для оценки квантиля каждой руки и выбирает руку с максимальной оценкой заданного квантиля.

Ключевая отличительная особенность Functional UCB заключается в том, что: он *адаптивно* подстраивает форму бонуса под степенную асимптотику хвоста через Hill-подобный estimator.

Таким образом, Functional UCB можно рассматривать как функциональное обобщение Heavy-Tail UCB, где функциональная зависимость бонуса от хвостового индекса α определяется типом распределения (лёгкие против тяжёлые хвосты), а не фиксируется априори.

5.2.6. Экспериментальная оценка на тяжёлых хвостах

Для каждой руки вычислялись истинные 0.75 и 0.9 квантили, и сожаление было определено как разница между квантилем оптимальной руки и квантилем текущей руки, выбранной алгоритмом. Было проведено четыре эксперимента для 0.75 квантиля и столько же для 0.9 квантиля:

- Парето $\alpha = 1.2, 1.8, 2.5$.
Рука 1: 0.75-квантиль = 3.1748,
Рука 2: 0.75-квантиль = 2.1601,
Рука 3: 0.75-квантиль = 1.7411,
- Парето $\alpha = 1.2, 1.8, 2.5$.
Рука 1: 0.9-квантиль = 6.8129,
Рука 2: 0.9-квантиль = 3.5938,
Рука 3: 0.9-квантиль = 2.5119,
- Парето: $\alpha = 1.05, 1.3, 2.0$.
Рука 1: 0.75-квантиль = 3.7445,
Рука 2: 0.75-квантиль = 2.9048,
Рука 3: 0.75-квантиль = 2.0000,
- Парето $\alpha = 1.05, 1.3, 2.0$.
Рука 1: 0.9-квантиль = 20.999,
Рука 2: 0.9-квантиль = 5.8780,
Рука 3: 0.9-квантиль = 3.1623,
- Коши $\gamma = 1.0, x_0 = 5.0, 4.0, 3.0$.
Рука 1: 0.75-квантиль = 6.0000,
Рука 2: 0.75-квантиль = 5.0000,
Рука 3: 0.75-квантиль = 4.0000,
- Коши $\gamma = 1.0, x_0 = 5.0, 4.0, 3.0$.
Рука 1: 0.9-квантиль = 8.0777,
Рука 2: 0.9-квантиль = 7.0777,
Рука 3: 0.9-квантиль = 6.0777,

– Нормальное распределение $\mu = 10.0, 9.0, 8.0, \sigma = 1.0$.

Рука 1: 0.75-квантиль = 10.6745,

Рука 2: 0.75-квантиль = 9.6745,


Рука 3: 0.75-квантиль = 8.6745,

– Нормальное распределение $\mu = 10.0, 9.0, 8.0, \sigma = 1.0$.


Рука 1: 0.9-квантиль = 11.2816,

Рука 2: 0.9-квантиль = 10.2816,

Рука 3: 0.9-квантиль = 9.2816,




(a) 0.75 квантиль




(b) 0.9 квантиль

Рисунок 5.1 – Парето $\alpha = 1.2, 1.8, 2.5$.




(a) 0.75 квантиль




(b) 0.9 квантиль

Рисунок 5.2 – Парето: $\alpha = 1.05, 1.3, 2.0$.

На рис.5.1- 5.4 продемонстрированы результаты работы экспериментов. Functional UCB 0.75-квантиль показывает лучший результат при распределении Парето с $\alpha = 1.05, 1.3, 2.0$. У распределения с данными параметрами существует среднее, но хвосты считаются очень тяжелыми. На нормальном распределении с легкими хво-




(a) 0.75 квантиль




(b) 0.9 квантиль

Рисунок 5.3 – Коши $\gamma = 1.0, x_0 = 5.0, 4.0, 3.0$.



(a) 0.75 квантиль



(b) 0.9 квантиль

Рисунок 5.4 – Нормальное распределение $\mu = 10.0, 9.0, 8.0, \sigma = 1.0$.

стами лучшим оказался классический UCB, при этом Functional UCB оказался не столь критически, но хуже.

Functional UCB 0.9-квантиль имеет лучшие результаты на распределениях Парето с $\alpha = 1.05, 1.3, 2.0$ и Коши. На нормальном распределении сильно проигрывает классическому UCB и HeavyTailUCB.

Из недостатков предложенного алгоритма можно выделить следующие пункты:

- алгоритм чувствителен к качеству оценки хвостового индекса α ;
- на малых выборках оценка Хилла может быть нестабильной, так как сильно зависит от отдельных экстремальных наблюдений;
- при лёгкохвостых распределениях алгоритм может давать избыточный исследовательский бонус и поэтому уступать классическому UCB;
- выбор числа верхних порядковых статистик

$$k(n) = \lfloor n^{0.65} \rfloor$$

является эвристическим и не гарантирует оптимальности для всех распределений;

- оценка Хилла требует положительных наблюдений, поэтому при нулевых или отрицательных наградах необходима предварительная обработка данных;
- квантильный критерий качества не совпадает с классическим регретом по математическому ожиданию, поэтому результаты экспериментов следует интерпретировать именно как сравнение алгоритмов по квантильному регрету.

ЗАКЛЮЧЕНИЕ

В ходе работы были получены следующие результаты.

Во-первых, были реализованы и сравнены линейные многорукие бандиты в синтетической задаче последовательного выбора действий с контекстными признаками. Результаты показали, что LinUCB быстрее снижает ошибку предсказания наград, чем ε -greedy и Thompson Sampling, что подтверждает эффективность использования контекстной информации в линейной среде. Однако ошибка восстановления истинного вектора весов w^* для LinUCB оказалась выше, чем у некоторых базовых алгоритмов. Это показывает, что в задаче многорукого бандита основным критерием качества является не точное восстановление параметров среды, а способность выбирать действия с высокой ожидаемой наградой. Следовательно, ошибка весов должна рассматриваться как вспомогательная диагностическая метрика, а не как главный показатель эффективности бандит-алгоритма.

Во-вторых, была построена мультиагентная модель динамики мнений, в которой агенты используют алгоритмы многоруких бандитов для выбора стратегии обновления мнения. В основной модели ручками бандита выступают стратегии поведения агента: сохранение текущего мнения, усреднение с соседями, компромиссное обновление, смещение вверх и смещение вниз. Графовая структура задаёт локальную информационную среду агента, а награда определяется через приближение мнения к внешней целевой позиции θ . Эксперименты на графах ER, BA и WS показали, что неконтекстные алгоритмы, прежде всего UCB и Thompson Sampling, могут обеспечивать более устойчивое поведение в данной постановке, чем контекстные методы. При этом данный результат не означает общего проигрыша контекстных бандитов: он относится именно к выбранному контекстному вектору, функции награды и набору стратегий обновления мнения. По данной теме статья принята в печать [44].

В-третьих, был исследован робастный аспект бандит-обучения на примере алгоритма FunctionalUCB. Показано, что использование квантильного критерия позволяет корректно сравнивать алгоритмы в условиях тяжёлых хвостов, где математическое ожидание может быть нестабильным или неопределённым. На распределениях Парето FunctionalUCB показал конкурентоспособные результаты по кумулятивному кван-

тельному регрету, особенно в случае выраженных тяжёлых хвостов. При этом на лёгкохвостом нормальном распределении преимущество получил классический UCB, что подтверждает ограниченную применимость FunctionalUCB: данный алгоритм целесообразен прежде всего в задачах, где распределения наград имеют тяжёлые хвосты. Также установлено, что качество FunctionalUCB существенно зависит от устойчивости оценки хвостового индекса, выбора параметра $k(n)$ и корректной предобработки наблюдений для применения оценки Хилла.

Все реализации алгоритмов и код для воспроизведения экспериментов доступны в репозитории: https://github.com/tarasonix/VKR_2026

Таким образом, работа показала, что алгоритмы многоруких бандитов могут использоваться как механизм адаптивного поведения агентов в моделях динамики мнений. Робастные алгоритмы типа FunctionalUCB полезны для анализа сред с тяжёлыми хвостами, линейные бандиты позволяют учитывать контекст действия, а неконтекстные алгоритмы в сетевой мультиагентной модели могут быть более устойчивыми при небольшом числе дискретных стратегий. Полученные результаты подтверждают, что выбор бандит-алгоритма должен зависеть от характера среды: распределения наград, структуры признаков, топологии графа и способа задания функции награды.

Список литературы

- [1] Николенко С. И., Архангельская Е., Трубачев А. Глубокое обучение. Учебный курс. СПб.: Питер, 2018. 480 с.
- [2] Парсегов С. Э. Мультиагентные системы и динамика мнений в социальных сетях // Труды Института проблем управления им. В.А. Трапезникова РАН. 2017. Т. 72. С. 2–18.
- [3] Zhao C. Моделирование динамики бинарных мнений в социальных сетях. Диссертация. СПбГУ, 2024.
- [4] Abbasi-Yadkori Y., Pál D., Szepesvári C. Improved Algorithms for Linear Stochastic Bandits // NIPS. 2011. Vol. 24. P. 2312–2320.
- [5] Abramiuk-Szurlej A. et al. Discontinuous phase transitions in the q-voter model // Scientific Reports. 2021. Vol. 11. P. 17719.
- [6] Agrawal S., Goyal N. Thompson Sampling for linear bandits // ICML. 2013. P. 127–135.
- [7] Agrawal S., Goyal N. Further optimal regret bounds for Thompson sampling // Artificial Intelligence and Statistics. 2013. P. 99-107.
- [8] Altafini C. Consensus problems on networks with antagonistic interactions // IEEE Transactions on Automatic Control. 2013. Vol. 58, No. 4. P. 935-946.
- [9] Arifin S., Rojak J. A. Social Media and Public Opinion Formation // Journal of Social Science Studies. 2022. Vol. 2, no. 1. P. 139–142.
- [10] Auer P., Cesa-Bianchi N., Fischer P. Finite-time analysis of the multiarmed bandit problem // Machine learning. 2002. Vol. 47, No. 2. P. 235-256.
- [11] Barabási A.-L., Albert R. Emergence of scaling in random networks // Science. 1999. Vol. 286. P. 509–512.
- [12] Berry D. A., Fristedt B. Bandit problems: sequential allocation of experiments. London: Chapman and Hall, 1985.

- [13] Bingham N. H., Goldie C. M., Teugels J. L. Regular variation. Cambridge University Press, 1987. Vol. 27.
- [14] Bubeck S., Cesa-Bianchi N. Regret Analysis of Stochastic and Nonstochastic Multi-armed Bandit Problems // Foundations and Trends in ML. 2012. Vol. 5, no. 1. P. 1–122.
- [15] Bubeck S., Cesa-Bianchi N., Lugosi G. Bandits with heavy tail // IEEE Trans. Inform. Theory. 2013. Vol. 59, no. 11. P. 7711–7717.
- [16] Cardoso A. R., Xu W. Bandit algorithms for quantile optimization // International Conference on Machine Learning. 2019. P. 906-915.
- [17] Chen H., Zhao X. Modeling and simulation of interactive public opinion evolution // Processes. 2022. Vol. 10, no. 7. P. 1379.
- [18] Chu W., Li L., Reyzin L., Schapire R. Contextual Bandits with Linear Payoff Functions // AISTATS. 2011. Vol. 15. P. 208–214.
- [19] DeGroot M. H. Reaching a consensus // Journal of the American Statistical Association. 1974. Vol. 69, no. 345. P. 118–121.
- [20] Embrechts P., Klüppelberg C., Mikosch T. Modelling extremal events: for insurance and finance. Springer, 1997. Vol. 33.
- [21] Erdős P., Rényi A. On random graphs // Publ. Math. Debrecen. 1959. Vol. 6. P. 290–297.
- [22] Fatas-Villafranca F., Saura D., Vazquez F. J. A dynamic model of public opinion formation // Journal of Public Economic Theory. 2011. Vol. 13, no. 3. P. 417–441.
- [23] Feller W. An introduction to probability theory and its applications. Vol. 2. John Wiley & Sons, 1971.
- [24] Frasca P., Tarbouriech S., Zaccarian L. Hybrid models of opinion dynamics // Automatica. 2019. Vol. 100. P. 153–161.
- [25] Friedkin N. E., Johnsen E. C. Social influence networks and opinion change // Advances in Group Processes. 1999. Vol. 16. P. 1–29.

- [26] Friedkin N. E., Johnsen E. C. Social influence and opinions // SIAM Review. 1990. Vol. 32, no. 1. P. 158–178.
- [27] Hill B. M. A simple general approach to inference about the tail of a distribution // Ann. Statist. 1975. Vol. 3, no. 5. P. 1163–1174.
- [28] Kozitsin I. V. A general framework to link theory and empirics in opinion formation models // Scientific Reports. 2022. Vol. 12, no. 1. P. 5543.
- [29] Kozitsin V. Predicting public opinion dynamics with the SCARDO-model // UBS. 2024. Issue 108. P. 124–136.
- [30] Lai T. L., Robbins H. Asymptotically efficient adaptive allocation rules // Advances in Applied Mathematics. 1985. Vol. 6, no. 1. P. 4–22.
- [31] Lattimore T., Szepesvári C. Bandit Algorithms. Cambridge University Press, 2020.
- [32] Li L. et al. A Contextual-Bandit Approach to Personalized News Article Recommendation // WWW. 2010. P. 661–670.
- [33] Li W., Parsegov S. E. Joint opinion and action dynamics in social networks // Automation and Remote Control. 2022. Vol. 83, no. 4. P. 580–595.
- [34] Mason D. M. Asymptotic normality of the Hill estimator // Comm. Statist. Theory Methods. 1982. Vol. 11, no. 15. P. 1701–1719.
- [35] Monica S., Bergenti F. An analytical study of opinion dynamics // Computers and Mathematics with Applications. 2017. Vol. 73, no. 12. P. 2272–2284.
- [36] Okawa M., Iwata T. Predicting opinion dynamics via sociologically-informed neural networks // KDD. 2022.
- [37] Robbins H. Some aspects of the sequential design of experiments // Bulletin of the AMS. 1952. Vol. 58, no. 5. P. 527–535.
- [38] Rusmevichientong P., Tsitsiklis J.N. Linearly Parameterized Bandits // Math. Oper. Res. 2010. Vol. 35, no. 2. P. 395–411.

- [39] Russell S., Norvig P. Artificial Intelligence: A Modern Approach. 4th ed. Pearson, 2016.
- [40] Russo D., Van Roy B. Learning to optimize via posterior sampling // Mathematics of Operations Research. 2014. Vol. 39, no. 4. P. 1221–1243.
- [41] Russo D. J. et al. A tutorial on Thompson sampling // Foundations and Trends in ML. 2018. Vol. 11, no. 1. P. 1–96.
- [42] Stern S. E. A modified Friedkin-Johnsen model for dynamic social networks // Social Networks. 2021. Vol. 67. P. 42-49.
- [43] Sutton R.S., Barto A.G. Reinforcement Learning: An Introduction. 2nd ed. MIT Press, 2018.
- [44] Tarasova S., Fedyanin D. Modeling Public Opinion Dynamics Through Multi-Agent Strategic Interaction Framework // Lecture Notes in Computer Science. — 2026. — Vol. 16715. — (in press).
- [45] Thompson W. R. On the likelihood that one unknown probability exceeds another // Biometrika. 1933. Vol. 25, no. 3–4. P. 285–294.
- [46] Wang C. An Opinion Dynamics Model with Increasing Self-Confidence // arXiv:1609.05732. 2016.
- [47] Watts D. J., Strogatz S. H. Collective dynamics of 'small-world' networks // Nature. 1998. Vol. 393. P. 440–442.
- [48] Xing Z., Ye M., Karyotis V. Joint learning of network topology and opinion dynamics // IFAC-PapersOnLine. 2023. Vol. 56, no. 2. P. 123–128.
- [49] Ye M. et al. Distributed Nash equilibrium seeking: A survey // Proc. IEEE. 2023. Vol. 111, no. 2. P. 140–157.
- [50] Ye M., Liu W., Zhang F. Consensus and control of opinion dynamics on social networks // IEEE Transactions on Automatic Control. 2017. Vol. 62, no. 5. P. 2301–2316.
- [51] Yi P. et al. A survey on noncooperative games over multi-agent networks // CAAI Artificial Intelligence Research. 2022. Vol. 1, no. 1. P. 8–27.